

第 34 章 扩散模型

扩散模型 (diffusion model) 是通过扩散过程定义的概率生成模型。扩散过程由前向 (扩散) 过程和反向 (去噪) 过程组成。扩散模型主要有去噪扩散概率模型 (denoising diffusion probabilistic model, DDPM) 和分数匹配加朗之万动力学 (score matching with Langevin dynamics, SMLD)。

去噪扩散概率模型 (DDPM) 中, 前向过程从原始数据开始, 通过多个步骤, 逐渐向数据添加噪声, 直到成为高斯白噪声。反向过程从高斯白噪声开始, 通过同样多个步骤, 逐渐去除噪声, 以还原原始数据。学习针对反向过程的每一步进行, 训练一个神经网络预测对应的前向过程中每一步的噪声, 从而有效地进行去噪, 也就是数据生成。

分数匹配加朗之万动力学 (SMLD) 学习和使用分数函数, 对应着反向过程, 隐式地存在前向过程。学习时, 针对原始数据添加不同程度的噪声, 训练一个神经网络, 拟合在不同噪声程度下的数据分布的分数函数。数据生成时, 使用学到的神经网络, 通过朗之万动力学从含有噪声的数据分布中采样, 逐渐减少噪声的程度, 最后生成与原始数据同分布的数据。

扩散过程是连续时间马尔可夫过程, 可以由随机微分方程刻画。扩散过程的前向过程和反向过程有相互对应的随机微分方程。DDPM 和 SMLD 实际可以看作是求解扩散过程的随机微分方程方法。

相比其他概率生成模型, 扩散模型在模型学习的准确性、生成数据的真实性和多样性等方面都具有一定的优势。目前被广泛应用于图像生成、语音生成、分子结构生成等任务。另一个概率生成模型, 流匹配模型与扩散模型是不同但密切相关的方法, 将在第 35 章进行讲解。

Sohl-Dickstein 等于 2015 年发表了扩散模型的基本算法, Song 和 Ermon 于 2019 年提出了 SMLD, Ho 等于 2020 年提出了被广泛使用的 DDPM。2020 年, Song 等阐述了随机微分方程与扩散模型的关系。

本章 34.1 节讲述 DDPM, 34.2 节讲述 SMLD, 34.3 节概述作为随机

微分方程解法的两者的关系，34.4 节介绍在图像生成中的应用。

34.1 基本原理

物理学中，扩散过程是指粒子在流体中带有随机性的运动过程。典型的情况是从高浓度区域向低浓度区域移动。比如，一滴墨水滴到一杯水中，起初从水面向水中渗透，随着时间的推移逐渐散开，最后均匀地溶解在水中。整体是一个扩散过程。

深度学习的扩散模型是受物理学扩散过程的启发而设计的数据的概率生成方法。深度学习的扩散模型可以应用于图像生成、语音生成、分子结构生成等任务。

前向过程 (forward process) 或者也称作扩散过程 (diffusion process) 是一个随机过程。给定一个数据样本，在随机过程的每一步，在样本上添加噪声，经过充分多的步数后，样本变成一个高斯白噪声。

相对地，反向过程 (backward process) 或者去噪过程 (denoising process) 也是一个随机过程。从一个高斯白噪声开始，在随机过程的每一步，对高斯白噪声进行去噪，经过充分多的步数后，得到一个数据样本。反向过程实际是从高斯白噪声到数据的生成过程。




图 34.1: 图像生成：前向过程，图像逐步变成高斯白噪声；反向过程，高斯白噪声逐步变成图像

图 34.1 示意扩散模型用于图像生成。样本数据通常是有结构的（样本之间存在相互依存关系），而高斯白噪声是无结构的（样本之间相互独立且样本遵循高斯分布）。注：高斯分布是在均值和方差确定的条件下熵最大的概率分布（见第 8 章）。前向过程将有结构数据逐步转换成无结构数据，而反向过程将无结构数据逐步转换成有结构数据。反向过程对应着，在杯中已然扩散的墨水，沿着与时间相反的方向，回退到刚滴到水中时的一滴，这种情况在物理世界是近乎不可能发生的。

前向过程与反向过程均具有马尔可夫性，即每一时刻的状态仅依赖于前一时刻的状态。该过程可在连续时间或离散时间条件下定义。DDPM 与

SMLD 均基于离散时间马尔可夫过程构建，其前向与反向过程各自有特定的转移概率分布。前向过程通过一步步的加噪实现，反向过程通过一步步的去噪实现，而且前向过程的一步有对应的反向过程的一步。数据生成的过程就是去噪的过程。

DDPM 和 SMLD 的前向过程都是事先设计好的，反向过程从数据中学习。学习到的模型用神经网络表示，实现一步的去噪。DDPM 的学习算法基于变分推理，SMLD 的学习算法基于去噪分数匹配。DDPM 和 SMLD 的去噪或生成过程都可以从分数匹配的角度理解，分数匹配是去噪或生成本质重要的概念。

DDPM 与 SMLD 最初是作为机器学习方法被提出的。而在更一般的设定中，扩散过程可建模为连续时间马尔可夫过程，并通过随机微分方程描述。事实上，DDPM 与 SMLD 可视为不同随机微分方程的离散时间的数值计算方法。因此，随机微分方程是对扩散过程建模的更为一般的手段。

34.2 去噪扩散概率模型

本节讲述去噪扩散概率模型 DDPM。首先介绍模型的定义和性质，接着叙述学习和生成算法。

34.2.1 模型的定义和性质

1. 前向过程和反向过程

训练数据是从未知的概率分布 $q(\mathbf{x})$ 抽样得到的样本，其中的一个样本由 $\mathbf{x}_0$ 表示。目标是从训练数据估计概率分布 $q(\mathbf{x})$ ，并根据估计的概率分布生成新的数据。这就是概率生成模型的学习和数据生成问题。

考虑扩散过程，由前向过程和反向过程组成。假设前向过程是一个马尔可夫过程，其状态对应样本，状态转移对应样本采样。从原始样本 $\mathbf{x}_0$ 开始，每一步根据马尔可夫过程的转移概率分布随机采样，等价于对样本加入噪声，得到一个加噪的样本，经过 T 步，得到高斯白噪声 $\mathbf{x}_T$ ：

$$\mathbf{x}_0 \rightarrow \mathbf{x}_1 \cdots \rightarrow \mathbf{x}_{t-1} \rightarrow \mathbf{x}_t \cdots \rightarrow \mathbf{x}_{T-1} \rightarrow \mathbf{x}_T$$

其中， $\mathbf{x}_0$ 是原始样本， $\mathbf{x}_T$ 是高斯白噪声，遵循标准高斯分布。

假设反向过程也是一个马尔可夫过程，其状态对应样本，状态转移对应样本采样。从高斯白噪声 $\mathbf{x}_T$ 开始，每一步根据马尔可夫过程的转移概率分

布随机采样，等价于从样本去除噪声，进行去噪，得到一个去噪的样本，经过 T 步，得到原始样本 $\mathbf{x}_0$ ：

$$\mathbf{x}_0 \leftarrow \mathbf{x}_1 \leftarrow \cdots \mathbf{x}_{t-1} \leftarrow \mathbf{x}_t \leftarrow \cdots \mathbf{x}_{T-1} \leftarrow \mathbf{x}_T$$

其中， $\mathbf{x}_T$ 是高斯白噪声， $\mathbf{x}_0$ 是原始样本。反向过程是前向过程的逆过程。前向过程和反向过程的每一个第 t 步 ($t = 1, 2, \dots, T$) 都是对应的。

前向过程的联合概率分布是

$$q(\mathbf{x}_0 \mathbf{x}_1 \cdots \mathbf{x}_T) = q(\mathbf{x}_0) q(\mathbf{x}_1 | \mathbf{x}_0) \cdots q(\mathbf{x}_T | \mathbf{x}_{T-1}) \quad (34.1)$$

反向过程的联合概率分布是

$$q(\mathbf{x}_0 \mathbf{x}_1 \cdots \mathbf{x}_T) = q(\mathbf{x}_T) q(\mathbf{x}_{T-1} | \mathbf{x}_T) \cdots q(\mathbf{x}_0 | \mathbf{x}_1) \quad (34.2)$$

考虑图像数据生成。图 34.2 中显示的是图像的样本空间，每一个图像是样本空间中的一个点。样本空间是高维的，但是图像数据一般分布在低维的流形上，位于图中蓝色区域。前向过程中原始图像一步步被添加噪声，最后变成高斯白噪声，主要位于图中绿色区域。反向过程是逆过程，高斯白噪声一步步被去除噪声，最后变成图像，这也是图像的生成过程。




图 34.2: 扩散过程在样本空间中（见文前彩图）

2. 前向过程

DDPM 的前向过程是将原始样本 $\mathbf{x}_0$ 逐步转换为高斯白噪声 $\mathbf{x}_T$ 的过程。假设前向过程的转移概率分布是高斯分布，就是说每一步添加的噪声是

高斯噪声。在第 t 步 ($t = 1, 2, \dots, T$) 有

$$\mathbf{x}_t \sim q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}) \quad (34.3)$$

其中, 系数 β_t 和 α_t 满足

$$0 < \beta_t < 1$$

$$\alpha_t = 1 - \beta_t$$

可以等价地表示为

$$\mathbf{x}_t = \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{\beta_t} \boldsymbol{\epsilon}_{t-1} \quad (34.4)$$

其中, $\boldsymbol{\epsilon}_{t-1}$ 遵循标准高斯分布 $\boldsymbol{\epsilon}_{t-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。称式 (34.4) 为 DDPM 前向过程的迭代公式。迭代公式第一项是确定性的, 第二项是随机的。

这里用到多元高斯分布的性质。若随机变量 $\mathbf{x}$ 遵循各向同性高斯分布 (isotropic Gaussian distribution) $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \sigma^2 \mathbf{I})$, 则 $\mathbf{x}$ 满足 $\mathbf{x} = \boldsymbol{\mu} + \sigma \boldsymbol{\epsilon}$, 其中随机变量 $\boldsymbol{\epsilon}$ 遵循标准高斯分布 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

基于密度函数和基于随机变量的两种表示形式各有方便使用之处。下面根据需要使用。在含有随机变量的神经网络 (如 VAE) 的学习中, 基于随机变量表示的参数变换又被称为再参数化技巧。

前向过程的联合概率分布表示为

$$q(\mathbf{x}_0 \mathbf{x}_1 \cdots \mathbf{x}_T) = q(\mathbf{x}_0) \mathcal{N}(\mathbf{x}_1; \sqrt{\alpha_1} \mathbf{x}_0, \beta_1 \mathbf{I}) \cdots \mathcal{N}(\mathbf{x}_T; \sqrt{\alpha_T} \mathbf{x}_{T-1}, \beta_T \mathbf{I})$$

前向过程有以下性质, 由引理给出。

引理 34.1 从第 0 步的原始样本 $\mathbf{x}_0$ 到第 t 步的样本 $\mathbf{x}_t$ 的转移概率分布是以下高斯分布:

$$q(\mathbf{x}_t | \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}) \quad (34.5)$$

这里 $\bar{\alpha}_t$ 满足

$$\bar{\alpha}_t = \alpha_1 \alpha_2 \cdots \alpha_t$$

证明 使用随机变量表示, 对 $\mathbf{x}_t$ 进行展开:

$$\begin{aligned} \mathbf{x}_t &= \sqrt{\alpha_t} \mathbf{x}_{t-1} + \sqrt{1 - \alpha_t} \boldsymbol{\epsilon}_{t-1} \\ &= \sqrt{\alpha_t} (\sqrt{\alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_{t-1}} \boldsymbol{\epsilon}_{t-2}) + \sqrt{1 - \alpha_{t-1}} \boldsymbol{\epsilon}_{t-1} \\ &= \sqrt{\alpha_t \alpha_{t-1}} \mathbf{x}_{t-2} + \sqrt{1 - \alpha_t \alpha_{t-1}} \tilde{\boldsymbol{\epsilon}}_{t-2} \\ &= \cdots \\ &= \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \tilde{\boldsymbol{\epsilon}}_0 \end{aligned}$$

其中, 随机变量 ϵ_{t-1} 和 ϵ_{t-2} 遵循标准高斯分布 $\epsilon_{t-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, $\epsilon_{t-2} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。其和的新随机变量 $\tilde{\epsilon}_{t-2} = \epsilon_{t-1} + \epsilon_{t-2}$ 也遵循标准高斯分布 $\tilde{\epsilon}_{t-2} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。

这里用到多元高斯分布的性质。两个各向同性高斯分布的随机变量之和依然遵循各向同性高斯分布

$$\begin{aligned} \mathbf{x}_1 &\sim \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_1, \sigma_1^2 \mathbf{I}), & \mathbf{x}_2 &\sim \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_2, \sigma_2^2 \mathbf{I}) \\ \mathbf{x}_1 + \mathbf{x}_2 &\sim \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_1 + \boldsymbol{\mu}_2, (\sigma_1^2 + \sigma_2^2) \mathbf{I}) \end{aligned}$$

这样, $\mathbf{x}_t$ 可以重新写作

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon} \quad \blacksquare$$

这个性质意味着, 从第 0 步的样本 $\mathbf{x}_0$ 到第 t 步的样本 $\mathbf{x}_t$ 的转移概率分布可以显式地表示。这样给定原始样本 $\mathbf{x}_0$, 可以直接采样, 或者说添加高斯噪声, 得到样本 $\mathbf{x}_t$ 。

这个性质也意味着, 当 t 趋于无穷时, 转移概率分布 $q(\mathbf{x}_t | \mathbf{x}_{t-1})$ 趋于标准高斯分布。由此, 当 T 充分大时, 样本 $\mathbf{x}_T$ 接近高斯白噪声。

$$\mathbf{x}_T \sim \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I})$$

经常取 $T = 1000$ 。在前向过程中设方差系数 β_t 充分小, $\beta_t \ll 1$, 并且逐渐增大。

$$\beta_1 < \beta_2 < \cdots < \beta_T$$

比如, 线性递增。

方差系数的大小代表添加高斯噪声的大小。图 34.2 的例中, 前向过程中, 样本在流形附近被添加的高斯噪声较小, 在接近原点, 即标准高斯分布的均值时, 被添加的高斯噪声较大。对应的反向过程中, 在原点附近进行高噪声的去噪, 在流形附近进行低噪声的去噪, 这样利于更好地学习扩散模型。这一点在 SMLD 中也有体现。

3. 反向过程

DDPM 的反向过程是将高斯白噪声 $\mathbf{x}_T$ 逐步转换为原始样本 $\mathbf{x}_0$ 的过程。设第 T 步的样本遵循标准高斯分布

$$\mathbf{x}_T \sim \mathcal{N}(\mathbf{x}_T; \mathbf{0}, \mathbf{I})$$

第 t 步到第 $t-1$ 步 ($t = 1, 2, \dots, T$) 有转移概率分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 。

一般不直接计算转移概率分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ ，因为这个计算是不可行的。通过贝叶斯定理知

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t) \propto q(\mathbf{x}_t|\mathbf{x}_{t-1})q(\mathbf{x}_{t-1})$$

其中， $q(\mathbf{x}_t|\mathbf{x}_{t-1})$ 是计算可行的，而 $q(\mathbf{x}_{t-1})$ 是计算不可行的。

但是，如果导入 $\mathbf{x}_0$ 问题就变得简单。在 $\mathbf{x}_0$ 给定条件下的转移概率分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ ，从前向过程可以方便地计算。事实上这个条件转移概率分布也是高斯分布，其均值和方差可以从前向过程推导得出。DDPM 基于反向过程的这个性质实现，是其主要技巧。

引理 34.2 第 t 步到第 $t-1$ 步在第 0 步的条件下的转移概率分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 是以下高斯分布：

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\boldsymbol{\beta}}_t \mathbf{I}) \quad (34.6)$$

其均值是

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)}{1 - \bar{\alpha}_t} \mathbf{x}_0$$

方差的系数是

$$\tilde{\boldsymbol{\beta}}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t$$

证明 使用贝叶斯定理，利用前向过程的转移概率是高斯分布的性质，可以推导出反向过程的条件转移概率分布也是高斯分布，并得到其概率密度函数。

$$\begin{aligned} & q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \\ &= \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_0)q(\mathbf{x}_t|\mathbf{x}_{t-1}, \mathbf{x}_0)}{q(\mathbf{x}_t|\mathbf{x}_0)} \\ &= \frac{q(\mathbf{x}_{t-1}|\mathbf{x}_0)q(\mathbf{x}_t|\mathbf{x}_{t-1})}{q(\mathbf{x}_t|\mathbf{x}_0)} \\ &= \frac{\mathcal{N}(\mathbf{x}_{t-1}; \sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0, (1 - \bar{\alpha}_{t-1})\mathbf{I})\mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t}\mathbf{x}_{t-1}, (1 - \alpha_t)\mathbf{I})}{\mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})} \\ &\propto \exp \left\{ -\frac{1}{2} \left[\frac{(\mathbf{x}_t - \sqrt{\alpha_t}\mathbf{x}_{t-1})^2}{\beta_t} + \frac{(\mathbf{x}_{t-1} - \sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_0)^2}{1 - \bar{\alpha}_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t}\mathbf{x}_0)^2}{1 - \bar{\alpha}_t} \right] \right\} \\ &= \exp \left\{ -\frac{1}{2} \left[\frac{\mathbf{x}_t^2 - 2\sqrt{\alpha_t}\mathbf{x}_t\mathbf{x}_{t-1} + \alpha_t\mathbf{x}_{t-1}^2}{\beta_t} + \frac{\mathbf{x}_{t-1}^2 - 2\sqrt{\bar{\alpha}_{t-1}}\mathbf{x}_{t-1}\mathbf{x}_0 + \bar{\alpha}_{t-1}\mathbf{x}_0^2}{1 - \bar{\alpha}_{t-1}} - \frac{(\mathbf{x}_t - \sqrt{\bar{\alpha}_t}\mathbf{x}_0)^2}{1 - \bar{\alpha}_t} \right] \right\} \\ &= \exp \left\{ -\frac{1}{2} \left[\left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \mathbf{x}_{t-1}^2 - 2 \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) \mathbf{x}_{t-1} + C(\mathbf{x}_t, \mathbf{x}_0) \right] \right\} \end{aligned}$$

$C(\mathbf{x}_t, \mathbf{x}_0)$ 是对 $\mathbf{x}_{t-1}$ 的定量, 高斯分布的方差系数是

$$\begin{aligned}\tilde{\beta}_t &= 1 / \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \\ &= \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t\end{aligned}$$

均值是

$$\begin{aligned}\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) &= \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) / \left(\frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} \right) \\ &= \left(\frac{\sqrt{\alpha_t}}{\beta_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}}{1 - \bar{\alpha}_{t-1}} \mathbf{x}_0 \right) \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} (1 - \alpha_t) \\ &= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)}{1 - \bar{\alpha}_t} \mathbf{x}_0\end{aligned}$$

■

根据引理 34.1, $\mathbf{x}_0$ 可以从 $\mathbf{x}_t$ 求出:

$$\mathbf{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}} (\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon) \quad (34.7)$$

代入 $\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0)$, 得到其只依赖于 $\mathbf{x}_t$ 的形式:

$$\begin{aligned}\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) &= \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} \mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)}{1 - \bar{\alpha}_t} \frac{1}{\sqrt{\bar{\alpha}_t}} (\mathbf{x}_t - \sqrt{1 - \bar{\alpha}_t} \epsilon) \\ &= \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{(1 - \alpha_t)}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right) \quad (34.8)\end{aligned}$$

4. 模型: 神经网络

前向过程和反向过程都是马尔可夫过程, 前向过程的转移概率分布是高斯分布 (等价于添加高斯噪声)。从前向过程的从第 $t-1$ 步到第 t 步的转移概率分布 $q(\mathbf{x}_t|\mathbf{x}_{t-1})$, 能够求出前向的从第 0 步到第 t 步的转移概率分布 $q(\mathbf{x}_t|\mathbf{x}_0)$ 和反向的第 0 步给定条件下的第 t 步到第 $t-1$ 步的条件转移概率分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 。后两者都是高斯分布。

前向过程表示一步步加噪的随机过程, 由超参数 β_t ($t = 1, 2, \dots, T$) 控制, 是事先确定的。反向过程表示一步步去噪的随机过程, 由学习得到的神经网络控制。

DDPM 用神经网络表示反向的转移概率分布 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t), t = 1, 2, \dots, T$ 。假设这个转移概率分布是高斯分布

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t)) \quad (34.9)$$

其均值和方差由神经网络决定。神经网络的输入是样本 $\mathbf{x}_t$ 和步数 t ，输出是均值 $\boldsymbol{\mu}_\theta$ 和方差 $\boldsymbol{\Sigma}_\theta$ ，参数是 θ 。

反向过程的联合概率分布表示为

$$p(\mathbf{x}_0 \mathbf{x}_1 \cdots \mathbf{x}_T) = p(\mathbf{x}_T) \mathcal{N}(\mathbf{x}_{T-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_T, T), \boldsymbol{\Sigma}_\theta(\mathbf{x}_T, T)) \cdots \mathcal{N}(\mathbf{x}_0; \boldsymbol{\mu}_\theta(\mathbf{x}_1, 1), \boldsymbol{\Sigma}_\theta(\mathbf{x}_1, 1))$$

假设每一步的协方差矩阵是对角阵。

$$\boldsymbol{\Sigma}_\theta(\mathbf{x}_t, t) = \sigma_t^2 \mathbf{I}$$

图 34.3 显示前向过程和反向过程中的第 t 步处理。前向过程（从右到左）从第 $t-1$ 步到第 t 步根据 $q(\mathbf{x}_t|\mathbf{x}_{t-1})$ 采样，由 $\mathbf{x}_{t-1}$ 得到 $\mathbf{x}_t$ 。反向过程（从左到右）从第 t 步到第 $t-1$ 步根据 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 采样，由 $\mathbf{x}_t$ 得到 $\mathbf{x}_{t-1}$ 。原理上 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 应该近似转移概率分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 。但 $q(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 难以计算，DDPM 实际使 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 近似条件转移概率分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 。




图 34.3: 扩散的前向和反向过程中的第 t 步处理

34.2.2 学习和生成算法

1. 变分原理

DDPM 利用变分推理原理从数据中学习概率生成模型，与变分自编码器 VAE 有相似之处。前向过程对应着编码，反向过程对应着解码。前向过程经过 T 步将原始样本“编码”成高斯白噪声，反向过程经过 T 步将高斯白噪声“解码”成原始样本。与变分自编码器的不同点在于编码并没有对原始样本进行压缩，解码也没有对高斯白噪声进行解压。也就是说，在扩散的前向和反向过程中样本向量的维度没有发生变化。另一个不同点是通过两个 T 步的随机过程进行编码和解码，而不是使用两个神经网络进行一步的

编码和解码。还有，扩散过程中编码和解码的 T 步是对应的；编码过程已经事先确定，解码过程需要学习。

同 VAE 一样，可以定义基于解码器分布 $p_{\theta}(\mathbf{x}_0)$ 的证据以及证据下界。

$$\log p_{\theta}(\mathbf{x}_0) \geq \mathbb{E}_{q(\mathbf{x}_1 \mathbf{x}_2 \cdots \mathbf{x}_T | \mathbf{x}_0)} \left[\log \frac{p_{\theta}(\mathbf{x}_0 \mathbf{x}_1 \cdots \mathbf{x}_T)}{q(\mathbf{x}_1 \mathbf{x}_2 \cdots \mathbf{x}_T | \mathbf{x}_0)} \right] \quad (34.10)$$

进一步对原始数据分布 $q(\mathbf{x}_0)$ 取期望，得到对应的期望证据以及期望证据下界。

$$\mathbb{E}_{q(\mathbf{x}_0)} \log p_{\theta}(\mathbf{x}_0) \geq \mathbb{E}_{q(\mathbf{x}_0 \mathbf{x}_1 \cdots \mathbf{x}_T)} \left[\log \frac{p_{\theta}(\mathbf{x}_0 \mathbf{x}_1 \cdots \mathbf{x}_T)}{q(\mathbf{x}_1 \mathbf{x}_2 \cdots \mathbf{x}_T | \mathbf{x}_0)} \right] \quad (34.11)$$

通过直接最大化期望证据学习模型的参数是计算不可行的。DDPM 的学习通过最大化期望证据下界进行。等价地最小化对应的损失函数 $L(\theta)$ 。

展开损失函数得到以下结果，其中以 $p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 近似 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 。

$L(\theta)$

$$\begin{aligned}
&= \mathbb{E}_{q(\mathbf{x}_0 \mathbf{x}_1 \dots \mathbf{x}_T)} \left[\log \frac{q(\mathbf{x}_1 \mathbf{x}_2 \dots \mathbf{x}_T | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 \mathbf{x}_1 \dots \mathbf{x}_T)} \right] \\
&= \mathbb{E}_{q(\mathbf{x}_0 \mathbf{x}_1 \dots \mathbf{x}_T)} \left[\log \frac{\prod_{t=1}^T q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \right] \\
&= \mathbb{E}_{q(\mathbf{x}_0 \mathbf{x}_1 \dots \mathbf{x}_T)} \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=1}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \right] \\
&= \mathbb{E}_{q(\mathbf{x}_0 \mathbf{x}_1 \dots \mathbf{x}_T)} \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_{t-1})}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
&= \mathbb{E}_{q(\mathbf{x}_0 \mathbf{x}_1 \dots \mathbf{x}_T)} \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \sum_{t=2}^T \log \frac{q(\mathbf{x}_t | \mathbf{x}_0)}{q(\mathbf{x}_{t-1} | \mathbf{x}_0)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
&= \mathbb{E}_{q(\mathbf{x}_0 \mathbf{x}_1 \dots \mathbf{x}_T)} \left[-\log p_\theta(\mathbf{x}_T) + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} + \log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{q(\mathbf{x}_1 | \mathbf{x}_0)} + \log \frac{q(\mathbf{x}_1 | \mathbf{x}_0)}{p_\theta(\mathbf{x}_0 | \mathbf{x}_1)} \right] \\
&= \mathbb{E}_{q(\mathbf{x}_0 \mathbf{x}_1 \dots \mathbf{x}_T)} \left[\log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{p_\theta(\mathbf{x}_T)} + \sum_{t=2}^T \log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} - \log p_\theta(\mathbf{x}_0 | \mathbf{x}_1) \right] \\
&= \mathbb{E}_{q(\mathbf{x}_0, \mathbf{x}_T)} \left[\log \frac{q(\mathbf{x}_T | \mathbf{x}_0)}{p_\theta(\mathbf{x}_T)} \right] + \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_0, \mathbf{x}_{t-1}, \mathbf{x}_t)} \left[\log \frac{q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)}{p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)} \right] - \mathbb{E}_{q(\mathbf{x}_0, \mathbf{x}_1)} [\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)] \\
&= \mathbb{E}_{q(\mathbf{x}_0)} [\text{KL}(q(\mathbf{x}_T | \mathbf{x}_0) || p_\theta(\mathbf{x}_T))] + \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_0, \mathbf{x}_t)} [\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) || p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t))] \\
&\quad + \mathbb{E}_{q(\mathbf{x}_0, \mathbf{x}_1)} [-\log p_\theta(\mathbf{x}_0 | \mathbf{x}_1)] \tag{34.12}
\end{aligned}$$

第五步利用前向过程的马尔可夫性 $q(\mathbf{x}_t | \mathbf{x}_{t-1}) = q(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{x}_0)$ 和贝叶斯定理。最后一步引入 KL 散度。

分布 $q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0)$ 是高斯分布，将其写作：

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\beta}_t \mathbf{I}) \tag{34.13}$$

$$\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon} \right) \tag{34.14}$$

与之对应，分布 $p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t)$ 也是高斯分布，将其写作：

$$p_\theta(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_\theta(\mathbf{x}_t, t), \sigma_t^2 \mathbf{I}) \tag{34.15}$$

$$\boldsymbol{\mu}_{\boldsymbol{\theta}}(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{x}_t, t) \right) \quad (34.16)$$

假设两个分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 和 $p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 均值具有相同形式；方差相同，即设 $\sigma_t^2 = \tilde{\beta}_t$ 或 $\sigma_t^2 = \beta_t$ 。因此，神经网络简化为 $\boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)$ ，其输入是样本 $\mathbf{x}_t$ 和步数 t ，输出是高斯噪声 $\boldsymbol{\epsilon}$ ， $\boldsymbol{\theta}$ 是参数。

2. 高斯噪声的预测

DDPM 的学习实际通过简化的损失函数的最小化进行，训练一个预测高斯噪声的神经网络。

将损失函数展开，第一项损失 L_T 如下：

$$L_T(\boldsymbol{\theta}) = \mathbb{E}_{q(\mathbf{x}_0)} [\text{KL}(q(\mathbf{x}_T|\mathbf{x}_0)||p_{\boldsymbol{\theta}}(\mathbf{x}_T))] \quad (34.17)$$

这个损失 L_T 是定量，对最小化不起作用。

中间各项的损失 $L_{t-1}(t = T, T-1, \dots, 2)$ 如下。通过计算分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 和 $p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 的 KL 散度的期望得到，期望是针对分布 $q(\mathbf{x}_0, \mathbf{x}_t)$ 的。

$$\begin{aligned} L_{t-1}(\boldsymbol{\theta}) &= \mathbb{E}_{q(\mathbf{x}_0, \mathbf{x}_t)} [\text{KL}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)||p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1}|\mathbf{x}_t))] \\ &= \mathbb{E}_{q(\mathbf{x}_0)q(\mathbf{x}_t|\mathbf{x}_0)} [\text{KL}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)||p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1}|\mathbf{x}_t))] \\ &= \mathbb{E}_{q(\mathbf{x}_0)q(\mathbf{x}_t|\mathbf{x}_0)} \left[\frac{1}{2\sigma^2(t)} \|\boldsymbol{\mu}(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)\|^2 \right] \\ &= \mathbb{E}_{q(\mathbf{x}_0)p(\boldsymbol{\epsilon})} \left[\frac{1}{2\sigma^2(t)} \left\| \frac{1}{\sqrt{\alpha_t}} \left[\mathbf{x}_t - \frac{(1 - \alpha_t)}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon} \right] - \frac{1}{\sqrt{\alpha_t}} \left[\mathbf{x}_t - \frac{(1 - \alpha_t)}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{x}_t, t) \right] \right\|^2 \right] \\ &= \mathbb{E}_{q(\mathbf{x}_0)p(\boldsymbol{\epsilon})} \left[\frac{1}{2\sigma^2(t)} \frac{(1 - \alpha_t)^2}{\alpha_t(1 - \bar{\alpha}_t)} \|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)\|^2 \right] \\ &= \mathbb{E}_{q(\mathbf{x}_0)p(\boldsymbol{\epsilon})} \left[\frac{1}{2\sigma^2(t)} \frac{(1 - \alpha_t)^2}{\alpha_t(1 - \bar{\alpha}_t)} \|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\boldsymbol{\epsilon}, t)\|^2 \right] \end{aligned} \quad (34.18)$$

第四步进行了再参数化。

最后一项损失 L_0 如下：

$$L_0(\boldsymbol{\theta}) = \mathbb{E}_{q(\mathbf{x}_0, \mathbf{x}_1)} [-\log p_{\boldsymbol{\theta}}(\mathbf{x}_0|\mathbf{x}_1)] \quad (34.19)$$

针对损失 $L_{t-1}, t = T, T-1, \dots, 2$ ，忽略系数，只对平方损失部分进行优化。针对损失 L_0 ，假设进行同样的平方损失优化。忽略损失 L_T ，这样得

到以下简化的整体损失函数：

$$\begin{aligned} L'(\theta) &= \sum_{t=1}^T \mathbb{E}_{q(\mathbf{x}_0)p(\epsilon)} [\|\epsilon - \epsilon_\theta(\mathbf{x}_t, t)\|^2] \\ &= \sum_{t=1}^T \mathbb{E}_{q(\mathbf{x}_0)p(\epsilon)} [\|\epsilon - \epsilon_\theta(\sqrt{\bar{\alpha}_t}\mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, t)\|^2] \end{aligned} \quad (34.20)$$

神经网络 $\epsilon_\theta(\mathbf{x}_t, t)$ 预测的是前向过程第 t 步的高斯噪声 ϵ ，其直观解释如下。前向过程，第 t 步通过加高斯噪声 ϵ 实现 $\mathbf{x}_{t-1}$ 到 $\mathbf{x}_t$ 的随机转换（加噪）；反向过程，第 t 步如果能从 $\mathbf{x}_t$ 预测高斯噪声 ϵ ，也就能实现满足扩散过程要求的从 $\mathbf{x}_t$ 到 $\mathbf{x}_{t-1}$ 的随机转换（去噪）。

将学习目标设为预测原始数据 $\mathbf{x}_0$ 在理论上是等价的（作为习题）。然而，实验结果证明，直接预测噪声 ϵ 能获得更好的性能。

反向过程的第 t 步到第 $t-1$ 步的转移概率分布，可以利用学习得到的神经网络 $\epsilon_\theta(\mathbf{x}_t, t)$ 计算。使用随机变量表示形式

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(\mathbf{x}_t, t) \right) + \sqrt{\beta_t} \epsilon \quad (34.21)$$

称式 (34.21) 为 DDPM 反向过程的迭代公式，用于数据生成。假设每一步的方差系数与对应的前向过程的方差系数相同， $\sigma_t = \sqrt{\beta_t}$ 。迭代公式第一项是确定性的，第二项是随机的。

3. 学习和生成算法

给定训练数据集 $\mathcal{T}$ ，可以通过梯度下降法对损失函数 (34.20) 进行优化，学习神经网络的参数。具体算法如下。

学习时，随机选取原始样本 $\mathbf{x}_0$ ，并随机选取步数 t 。第 t 步的样本 $\mathbf{x}_t$ 是基于原始样本 $\mathbf{x}_0$ 和高斯噪声 ϵ 得到的。预测在样本 $\mathbf{x}_t$ 和步数 t 给定条件下，如何去除高斯噪声 ϵ 的影响，得到第 $t-1$ 步的样本 $\mathbf{x}_{t-1}$ 。也就是说，训练的目的在于去噪。

算法 34.1 (DDPM——学习算法)

输入：训练数据集 $\mathcal{T}$ 。

输出：神经网络 ϵ_θ 。

超参数： $\beta_t, t = 1, 2, \dots, T$ 。

- (1) 初始化神经网络的参数 θ 。
- (2) 重复以下处理，直到收敛：

- (2-1) 从训练数据集 $\mathcal{T}$ 中采样得到样本 $\mathbf{x}_0$;
- (2-2) 随机采样 $\{T, T-1, \dots, 1\}$ 得到步数 t ;
- (2-3) 随机采样 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 得到高斯噪声;
- (2-4) 计算损失函数的梯度并更新神经网络参数:

$$\nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, t)\|^2$$

- (3) 输出估计的神经网络模型。 ■

生成过程就是反向过程。使用学到的神经网络进行每一步的数据生成。

算法 34.2 (DDPM——生成算法)

输入: 神经网络 $\boldsymbol{\epsilon}_{\boldsymbol{\theta}}$ 。

输出: 生成的样本 $\mathbf{x}_0$ 。

超参数: $\beta_t, (t = 1, 2, \dots, T)$ 。

- (1) 随机采样得到高斯白噪声 $\mathbf{x}_T$ 。
- (2) For $(t = T, T-1, \dots, 1)\{$
 - (2-1) 随机采样 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 得到高斯噪声 $\boldsymbol{\epsilon}$;
 - (2-2) If $t = 1$, then $\boldsymbol{\epsilon} = \mathbf{0}$;
 - (2-3) 从第 t 步的样本 $\mathbf{x}_t$ 计算第 $t-1$ 步的样本 $\mathbf{x}_{t-1}$:

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{x}_t, t) \right) + \sqrt{\beta_t} \boldsymbol{\epsilon}$$

}

- (3) 输出生成的样本 $\mathbf{x}_0$ 。 ■

4. 分数函数的预测

DDPM 的学习一般用神经网络预测前向过程的高斯噪声。但也有另一种形式, 预测前向过程的分数函数。DDPM 和 SMLD 通过分数函数学习联系在一起。下面解释 DDPM 的分数函数形式的学习算法。

贝叶斯估计中, 假设观测数据 $\mathbf{x}$ 是随机变量, 遵循高斯分布。

$$\mathbf{x} \sim p(\mathbf{x}) = \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$$

其中均值 $\boldsymbol{\mu}$ 也是随机变量, 并拥有先验概率分布, 方差 $\boldsymbol{\Sigma}$ 是定量。Tweedie 公式给出观测数据 $\mathbf{x}$ 给定条件下的均值 $\boldsymbol{\mu}$ 针对后验概率分布的期望。

$$\mathbb{E}[\boldsymbol{\mu}|\mathbf{x}] = \mathbf{x} + \boldsymbol{\Sigma} \nabla_{\mathbf{x}} \log p(\mathbf{x}) \quad (34.22)$$

这里 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 是分数函数，其定义在 34.3 节给出。

DDPM 的前向过程中从样本 $\mathbf{x}_0$ 到样本 $\mathbf{x}_t$ 的转移概率分布是

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

应用 Tweedie 公式得到以下结论。

引理 34.3 前向过程中，在样本 $\mathbf{x}_t$ 给定条件下，均值 $\sqrt{\bar{\alpha}_t}\mathbf{x}_0$ 的后验期望是

$$\mathbb{E}[\sqrt{\bar{\alpha}_t}\mathbf{x}_0|\mathbf{x}_t] = \mathbf{x}_t + (1 - \bar{\alpha}_t)\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) \quad (34.23)$$

注意这里 $\mathbf{x}_0$ 是变量。

均值 $\sqrt{\bar{\alpha}_t}\mathbf{x}_0$ 近似等于后验期望

$$\sqrt{\bar{\alpha}_t}\mathbf{x}_0 \approx \mathbf{x}_t + (1 - \bar{\alpha}_t)\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t)$$

进而有

$$\mathbf{x}_0 = \frac{1}{\sqrt{\bar{\alpha}_t}}\mathbf{x}_t + \frac{(1 - \bar{\alpha}_t)}{\sqrt{\bar{\alpha}_t}}\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) \quad (34.24)$$

也得到前向过程中从样本 $\mathbf{x}_0$ 到样本 $\mathbf{x}_t$ 的变换关系

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\mathbf{x}_0 - (1 - \bar{\alpha}_t)\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) \quad (34.25)$$

比较式 (34.14) 和式 (34.25) 得到 DDPM 中的分数函数和高斯噪声的关系。

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) = -\frac{1}{\sqrt{1 - \bar{\alpha}_t}}\boldsymbol{\epsilon} \quad (34.26)$$

反向过程的条件转移概率分布 $q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)$ 是高斯分布，其均值是

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}\mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)}{1 - \bar{\alpha}_t}\mathbf{x}_0$$

将式 (34.24) 代入得到：

$$\tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0) = \frac{1}{\sqrt{\alpha_t}}[\mathbf{x}_t + (1 - \alpha_t)\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t)] \quad (34.27)$$

转移概率分布 $p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1}|\mathbf{x}_t)$ 也是高斯分布，其均值是

$$\boldsymbol{\mu}_{\boldsymbol{\theta}}(\mathbf{x}_t, t) = \frac{1}{\sqrt{\alpha_t}}[\mathbf{x}_t + (1 - \alpha_t)\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)] \quad (34.28)$$

其中， $\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)$ 表示神经网络。

定义变分下界以及损失函数，其中的损失 L_{t-1} 如下。

$$\begin{aligned}
 L_{t-1}(\boldsymbol{\theta}) &= \mathbb{E}_{q(\mathbf{x}_0)p(\epsilon)} [\text{KL}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) || p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1}|\mathbf{x}_t))] \\
 &= \mathbb{E}_{q(\mathbf{x}_0)p(\epsilon)} \left[\frac{1}{2\sigma_t^2} \|\boldsymbol{\mu}(\mathbf{x}_t, \mathbf{x}_0) - \boldsymbol{\mu}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)\|^2 \right] \\
 &= \mathbb{E}_{q(\mathbf{x}_0)p(\epsilon)} \left[\frac{1}{2\sigma_t^2} \frac{(1 - \alpha_t)^2}{\alpha_t(1 - \bar{\alpha}_t)} \|\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) - \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)\|^2 \right] \quad (34.29)
 \end{aligned}$$

这样就得到 DDPM 的另一个算法，神经网络 $\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)$ 预测的是前向过程第 t 步的分数函数。具体算法的整理留作习题。

对应的反向过程的迭代公式是

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} (\mathbf{x}_t + \beta_t \nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t)) + \sqrt{\beta_t} \epsilon \quad (34.30)$$

34.3 分数匹配加朗之万动力学

本节讲述分数匹配加朗之万动力学 (SMLD)。首先介绍分数匹配和朗之万动力学，然后讲述 SMLD 方法。

34.3.1 分数匹配

1. 分数函数

分数匹配是一种概率生成模型（概率分布的密度函数）的学习方法。这里首先给出分数函数的定义。假设概率分布的密度函数为

$$p(\mathbf{x}), \quad \mathbf{x} \in \mathbb{R}^d$$

称密度函数的对数对数据的梯度为分数函数 (score function)。

$$\nabla_{\mathbf{x}} \log p(\mathbf{x})$$

分数函数表示的是概率分布在样本空间的变化趋势。

分数函数 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 构成向量场，而密度函数 $p(\mathbf{x})$ 构成标量场，两者存在在归一化条件下的一一对应关系。通过对密度函数的微分可以求得分数函数，通过对分数函数的积分可以求得密度函数。

图 34.4 显示二元高斯混合模型的密度函数和分数函数，其密度函数是

$$p(\mathbf{x}) = \pi_1 \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_1, \mathbf{I}) + \pi_2 \mathcal{N}(\mathbf{x}; \boldsymbol{\mu}_2, \mathbf{I})$$

设 $\pi_1 = 0.6$, $\pi_2 = 0.4$, $\boldsymbol{\mu}_1 = (2, 2)^T$, $\boldsymbol{\mu}_2 = (-2, -2)^T$ 。密度函数由等高线表示。分数函数由有向线段表示；长短表示分数向量的大小，箭头表示分数向量的方向。模型由两个高斯分布组成，所以有两个山峰。分数向量指向概率密度增加的方向；在山坡处取值较大，在山峰处接近为零。




图 34.4: 分数函数

假设概率分布 $p_{\boldsymbol{\theta}}(\mathbf{x})$ 为吉布斯分布 (Gibbs distribution)

$$p_{\boldsymbol{\theta}}(\mathbf{x}) = \frac{\exp(-f_{\boldsymbol{\theta}}(\mathbf{x}))}{Z_{\boldsymbol{\theta}}} \quad (34.31)$$

其中, $f_{\boldsymbol{\theta}}(\mathbf{x})$ 是能量函数, $\boldsymbol{\theta}$ 是其参数; $Z_{\boldsymbol{\theta}}$ 是归一化项, 以满足概率分布条件 $\int p_{\boldsymbol{\theta}}(\mathbf{x}) d\mathbf{x} = 1$ 。吉布斯分布的特殊情况是玻尔兹曼分布 (Boltzmann distribution)

$$p_{\boldsymbol{\theta}}(\mathbf{x}) = \frac{\exp(-U_{\boldsymbol{\theta}}(\mathbf{x})/k_B T)}{Z_{\boldsymbol{\theta}}} \quad (34.32)$$

其中 $U_{\boldsymbol{\theta}}(\mathbf{x})$ 是势能函数, k_B 是玻尔兹曼常数, T 是温度。

针对玻尔兹曼分布, 分数函数变成

$$\nabla_{\mathbf{x}} \log p_{\boldsymbol{\theta}}(\mathbf{x}) = -\frac{1}{k_B T} \nabla_{\mathbf{x}} U_{\boldsymbol{\theta}}(\mathbf{x}) \quad (34.33)$$

对应着物理学中的以下关系。分数函数表示的是保守力的向量场，比如重力的向量场，向量指向的方向是势能降低的方向，也就是概率密度增加的方向（图 34.4）。

2. 一般分数匹配

考虑概率生成模型的学习和数据生成问题。训练数据集是未知的概率分布 $q(\mathbf{x})$ 的随机样本。

$$\mathcal{T} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$$

概率分布 $p_{\theta}(\mathbf{x})$ 是要学习的模型，是吉布斯分布，用以近似表示 $q(\mathbf{x})$ 。

最直接的方法是使用极大似然估计。可以通过最小化对数损失函数，估计模型的参数。

$$L(\theta) = \mathbb{E}_{q(\mathbf{x})} [-\log p_{\theta}(\mathbf{x})] \quad (34.34)$$

过程中需要计算归一化项 Z_{θ} ，其直接计算复杂度高，往往是不可行的。

分数匹配方法（score matching）可以规避上述计算不可行的问题。具体而言，把学习的目标定为学习概率分布的分数函数，而不是学习概率分布的密度函数。在应用中使用分数函数，而不是密度函数，如后述朗之万动力学就是如此。针对吉布斯分布，分数函数变成

$$\nabla_{\mathbf{x}} \log p_{\theta}(\mathbf{x}) = -\nabla_{\mathbf{x}} f_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} Z_{\theta} = -\nabla_{\mathbf{x}} f_{\theta}(\mathbf{x})$$

只需要计算能量函数对数据的负梯度，不需要计算归一化项。注意这里是对数据 $\mathbf{x}$ 求梯度，而不是对参数 θ 求梯度，所以归一化项的梯度为 0。

分数匹配方法具体用神经网络表示分数函数：

$$\mathbf{s}_{\theta}(\mathbf{x}) = \nabla_{\mathbf{x}} \log p_{\theta}(\mathbf{x}) = -\nabla_{\mathbf{x}} f_{\theta}(\mathbf{x}) \quad (34.35)$$

从数据中学习这个神经网络。学习通过最小化以下损失函数进行。

$$L_{\text{esm}}(\theta) = \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_{\theta}(\mathbf{x}) - \nabla_{\mathbf{x}} \log q(\mathbf{x})\|^2 \right] \quad (34.36)$$

损失函数 L_{esm} 实际是费舍尔散度（Fisher divergence）。学习方法称为显式分数匹配（explicit score matching）。

这里 $\nabla_{\mathbf{x}} \log q(\mathbf{x})$ 表示要学习的分布的分数函数的真值，学习时是未知的，看似这个问题不可解。有趣的是，分数匹配的优化问题可以通过等价问

题进行，也就是最小化以下的损失函数 L_{ism} ，这样就不需要知道分数函数的真值。学习方法称为隐式分数匹配 (implicit score matching)。

$$L_{\text{ism}}(\boldsymbol{\theta}) = \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x})\|^2 + \nabla_{\mathbf{x}} \cdot \mathbf{s}_{\boldsymbol{\theta}}(\mathbf{x}) \right] \quad (34.37)$$

其中 $\nabla_{\mathbf{x}} \cdot$ 是散度算子。

定理 34.1 最小化隐式分数匹配的目标函数 L_{ism} 等价于最小化显示分数匹配的目标函数 L_{esm} 。

$$\min_{\boldsymbol{\theta}} L_{\text{ism}}(\boldsymbol{\theta}) = \min_{\boldsymbol{\theta}} L_{\text{esm}}(\boldsymbol{\theta}) \quad (34.38)$$

这个优化问题仍然有计算效率的问题。计算第 2 项需要计算分数匹配模型的散度，当数据是高维时，计算复杂度较高，隐式分数匹配方法并不实用。

3. 去噪分数匹配

去噪分数匹配 (denoising score matching) 对原始数据添加少量随机噪声，学习加噪数据的分数匹配函数，用于估计原始数据的分数匹配函数，同时解决显示分数匹配方法计算效率不高的问题。

添加随机噪声使用条件高斯分布，其中 σ^2 是方差系数，控制噪声的大小。

$$q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}; \mathbf{x}, \sigma^2 \mathbf{I}) \quad (34.39)$$

学习时最小化以下平方损失函数。

$$L_{\text{dsm}}(\boldsymbol{\theta}) = \mathbb{E}_{q(\mathbf{x})q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}}) - \nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})\|^2 \right] \quad (34.40)$$

这时根据条件高斯分布 $\mathcal{N}(\tilde{\mathbf{x}}; \mathbf{x}, \sigma^2 \mathbf{I})$ 从原始样本 $\mathbf{x}$ 采样得到加噪样本 $\tilde{\mathbf{x}}$ 。分数函数 $\nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})$ 有解析解，并且可以高效计算。

$$\nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) = -\frac{\tilde{\mathbf{x}} - \mathbf{x}}{\sigma^2} \quad (34.41)$$

这样学到的神经网络 $\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})$ 可以表示加噪数据的分数匹配函数 $\nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}})$ 。有以下定理保证。定理在更一般的条件下成立，并不要求加噪数据分布是高斯分布。

定理 34.2 最小化去噪分数匹配的目标函数 L_{dsm} 等价于最小化显示分数匹配的目标函数 L_{esm} 。

$$\min_{\boldsymbol{\theta}} L_{\text{dsm}}(\boldsymbol{\theta}) = \min_{\boldsymbol{\theta}} L_{\text{esm}}(\boldsymbol{\theta}) \quad (34.42)$$

证明 将目标函数 L_{esm} 根据定义展开

$$\begin{aligned} L_{\text{esm}}(\boldsymbol{\theta}) &= \mathbb{E}_{q(\tilde{\mathbf{x}})} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}}) - \nabla_{\tilde{\mathbf{x}}} \log q(\tilde{\mathbf{x}})\|^2 \right] \\ &= \mathbb{E}_{q(\tilde{\mathbf{x}})} \left[\frac{1}{2} \|\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})\|^2 - \mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \nabla_{\tilde{\mathbf{x}}} \log q(\tilde{\mathbf{x}}) + \frac{1}{2} \|\nabla_{\tilde{\mathbf{x}}} \log q(\tilde{\mathbf{x}})\|^2 \right] \end{aligned}$$

其中第二项可以写作

$$\begin{aligned} \mathbb{E}_{q(\tilde{\mathbf{x}})} \left[\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \nabla_{\tilde{\mathbf{x}}} \log q(\tilde{\mathbf{x}}) \right] &= \int (\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \nabla_{\tilde{\mathbf{x}}} \log q(\tilde{\mathbf{x}})) q(\tilde{\mathbf{x}}) d\tilde{\mathbf{x}} \\ &= \int \mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \nabla_{\tilde{\mathbf{x}}} q(\tilde{\mathbf{x}}) d\tilde{\mathbf{x}} \end{aligned}$$

利用事实 $q(\tilde{\mathbf{x}}) = \int q(\mathbf{x}) q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) d\mathbf{x}$ 可以推导出

$$\begin{aligned} \int \mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \nabla_{\tilde{\mathbf{x}}} q(\tilde{\mathbf{x}}) d\tilde{\mathbf{x}} &= \int \mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \nabla_{\tilde{\mathbf{x}}} \left(\int q(\mathbf{x}) q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) d\mathbf{x} \right) d\tilde{\mathbf{x}} \\ &= \int \mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \left(\int q(\mathbf{x}) \nabla_{\tilde{\mathbf{x}}} q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) d\mathbf{x} \right) d\tilde{\mathbf{x}} \\ &= \int \mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \left(\int q(\mathbf{x}) q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) \nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) d\mathbf{x} \right) d\tilde{\mathbf{x}} \\ &= \int \int q(\mathbf{x}) q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) \left(\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) \right) d\mathbf{x} d\tilde{\mathbf{x}} \\ &= \mathbb{E}_{q(\mathbf{x}) q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})} \left[\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) \right] \quad (34.43) \end{aligned}$$

代回到目标函数 L_{esm} 得到

$$L_{\text{esm}}(\boldsymbol{\theta}) = \frac{1}{2} \mathbb{E}_{q(\mathbf{x}) q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})} [\|\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})\|^2] - \mathbb{E}_{q(\mathbf{x}) q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x})} \left[\mathbf{s}_{\boldsymbol{\theta}}(\tilde{\mathbf{x}})^{\text{T}} \nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}}|\mathbf{x}) \right] + C_1$$

其中第三项不依赖于变量 $\boldsymbol{\theta}$ ，由常数 C_1 表示。

将目标函数 L_{dsm} 根据定义展开

$$\begin{aligned}
 L_{\text{dsm}}(\boldsymbol{\theta}) &= \mathbb{E}_{q(\mathbf{x})q_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_\theta(\tilde{\mathbf{x}}) - \nabla_{\tilde{\mathbf{x}}} \log q_\sigma(\tilde{\mathbf{x}}|\mathbf{x})\|^2 \right] \\
 &= \mathbb{E}_{q(\mathbf{x})q_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_\theta(\tilde{\mathbf{x}})\|^2 - \mathbf{s}_\theta(\tilde{\mathbf{x}})^\top \nabla_{\tilde{\mathbf{x}}} \log q(\tilde{\mathbf{x}}|\mathbf{x}) + \frac{1}{2} \|\nabla_{\tilde{\mathbf{x}}} \log q(\tilde{\mathbf{x}}|\mathbf{x})\|^2 \right] \\
 &= \mathbb{E}_{q(\mathbf{x})q_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \left[\frac{1}{2} \|\mathbf{s}_\theta(\tilde{\mathbf{x}})\|^2 \right] - \mathbb{E}_{q(\mathbf{x})q_\sigma(\tilde{\mathbf{x}}|\mathbf{x})} \left[\mathbf{s}_\theta(\tilde{\mathbf{x}})^\top \nabla_{\tilde{\mathbf{x}}} \log q_\sigma(\tilde{\mathbf{x}}|\mathbf{x}) \right] + C_2
 \end{aligned} \tag{34.44}$$

其中第三项不依赖于变量 $\boldsymbol{\theta}$ ，由常数 C_2 表示。

比较式 (34.43) 和式 (34.44) 得到

$$L_{\text{dsm}}(\boldsymbol{\theta}) = L_{\text{esm}}(\boldsymbol{\theta}) + C_2 - C_1$$

■

推论 34.1 当加噪的系数 σ 充分小时，通过去噪分数匹配学习到的最优分数函数 $\mathbf{s}_{\theta^*}(\mathbf{x})$ 是真实分数函数 $\nabla_{\mathbf{x}} \log q(\mathbf{x})$ 的良好近似。

$$\mathbf{s}_{\theta^*}(\mathbf{x}) \approx \nabla_{\mathbf{x}} \log q(\mathbf{x}) \tag{34.45}$$

34.3.2 朗之万动力学

朗之万动力学是物理学中用于描述粒子在流体中的随机运动的随机微分方程。(在过阻尼条件下的) 朗之万方程的随机微分方程形式是

$$d\mathbf{x} = -\frac{1}{\gamma} \nabla_{\mathbf{x}} U(\mathbf{x}) dt + \sqrt{\frac{2k_B T}{\gamma}} d\mathbf{w} \tag{34.46}$$

这里 $\mathbf{x}$ 是粒子在空间的位置， t 是时间， γ 是摩擦系数， $U(\mathbf{x})$ 是势能函数， $\nabla_{\mathbf{x}} U(\mathbf{x})$ 代表保守力， k_B 是玻尔兹曼常数， T 是温度， $d\mathbf{w}$ 是后述维纳过程。

朗之万动力学方程的解 $\mathbf{x}(t)$ 是一个随机过程。右侧第一项是确定性函数，而第二项是随机过程，两者的综合作用，决定了粒子在流体中的运动轨迹。理论保证，在正常的正则条件下，经过足够长的时间后，流体系统总会达到平衡状态，这时粒子的分布服从玻尔兹曼分布 $p(\mathbf{x}) \propto \exp(-U(\mathbf{x})/k_B T)$ 。

设 $\delta = k_B T / \gamma$ ，因为 $\nabla_{\mathbf{x}} \log p(\mathbf{x}) = -\frac{1}{k_B T} \nabla_{\mathbf{x}} U(\mathbf{x})$ ，所以随机微分方程可以进一步写作

$$d\mathbf{x} = \delta \nabla_{\mathbf{x}} \log p(\mathbf{x}) dt + \sqrt{2\delta} d\mathbf{w} \tag{34.47}$$

朗之万动力学应用于机器学习成为概率分布的随机采样方法，也被称为朗之万蒙特卡洛法 (Langevin Monte Carlo)。假设概率分布是更一般的吉布斯分布 $p(\mathbf{x}) \propto \exp(-f(\mathbf{x}))$ ，其分数函数为 $\nabla_{\mathbf{x}} \log p(\mathbf{x}) = -\nabla_{\mathbf{x}} f(\mathbf{x})$ 。使用分数函数对概率分布进行采样，得到概率分布 $p(\mathbf{x})$ 的样本。

首先从一个固定分布采样，如标准高斯分布，得到样本 $\mathbf{x}^{(0)}$ ，然后通过以下迭代公式持续进行采样。

$$\mathbf{x}^{(l)} = \mathbf{x}^{(l-1)} + \delta \nabla_{\mathbf{x}} \log p(\mathbf{x}^{(l-1)}) + \sqrt{2\delta} \epsilon, \quad l = 1, 2, \dots, L \quad (34.48)$$

其中， $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是高斯噪声， $\delta > 0$ 是步长系数。事实上这是随机微分方程 (34.47) 最基本的数值计算方法，即欧拉-丸山方法的迭代公式。

在迭代过程中， $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ 驱使样本向高概率区域移动，而 ϵ 则引入随机扰动，促使样本探索整个概率分布区域，避免陷入局部点。二者共同作用，使样本最终收敛于分布 $p(\mathbf{x})$ 。

可以证明，当 $\delta \rightarrow 0$ 且 $L \rightarrow \infty$ 时，采样收敛到目标的吉布斯分布 $p(\mathbf{x})$ 。现实中，当 δ 充分小且 L 充分大时， $\mathbf{x}^{(L)}$ 可以近似地看作该分布的样本。

朗之万蒙特卡洛法只需要知道 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ ，并不需要知道 $p(\mathbf{x})$ ，就可以进行对 $p(\mathbf{x})$ 的采样。如果通过分数匹配法学到 $\mathbf{s}_{\theta}(\mathbf{x})$ ，以之代替 $\nabla_{\mathbf{x}} \log p(\mathbf{x})$ ，进行上述采样，这样就得到一个分数匹配的采样方法。

图 34.5 显示朗之万动力学采样应用于图 34.4 的二元高斯混合模型上的结果，迭代次数为 2000，样本个数为 100。

34.3.3 学习和生成算法

下面讲述 SMLD 方法。

目标是学习数据的概率生成模型，并对学到的概率分布进行采样以进行数据生成。一个简单的方法是将去噪分数匹配与朗之万动力学结合。首先通过去噪分数匹配学习概率分布的分数函数，然后通过朗之万动力学进行采样，在此过程中使用学到的概率分布。然而，这个方法的数据生成效果并不理想。

SMLD 的做法是在原始数据上添加不同水平的高斯噪声，应用去噪分数匹配的原理，用一个神经网络同时学习在不同噪声水平下的加噪数据的概率分布的分数函数。高斯噪声的方差系数表示噪声的水平，也作为神经网络




图 34.5: 高斯混合模型和朗之万动力学采样的 100 个样本

络的输入。方差系数小的时候，添加的噪声小；方差系数大的时候，添加的噪声大。学到不同噪声水平下的分数函数以后，再用朗之万动力学从高噪声的分布向低噪声的分布依次进行数据采样。理论上，最后得到的数据接近真实分布的采样。因为是从高噪声分布到低噪声分布依次进行的朗之万动力学采样，这个采样方法被称为退火朗之万动力学 (annealed Langevin dynamics)。

假设有 $t = 1, 2, \dots, T$ 个噪声水平。经常取 $T = 1000$ 。对应每一个噪声水平有一个条件高斯分布。

$$\mathbf{x}_t \sim q_{\sigma_t}(\mathbf{x}_t | \mathbf{x}) = \mathcal{N}(\mathbf{x}_t; \mathbf{x}, \sigma_t^2 \mathbf{I})$$

或者写作

$$\mathbf{x}_t = \mathbf{x} + \sigma_t \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

假设方差系数满足

$$\sigma_1 < \sigma_2 < \cdots < \sigma_T$$

设 σ_1 充分小, 根据推论 34.1, 有以下关系成立

$$q_{\sigma_1}(\mathbf{x}) \approx q(\mathbf{x})$$

这里 $q_{\sigma_1}(\mathbf{x}_1) = \int q_{\sigma_1}(\mathbf{x}_1|\mathbf{x})q(\mathbf{x})d\mathbf{x}$ 。

对原始数据 $\mathbf{x}$ 加方差系数为 σ_t 的噪声, 得到数据 $\mathbf{x}_t$, 从加噪数据 $\mathbf{x}_t$ 学习神经网络 $\mathbf{s}_\theta(\mathbf{x}_t, \sigma_t)$, $t = 1, 2, \dots, T$ 。最后将 $\mathbf{s}_\theta(\mathbf{x}_1, \sigma_1)$ 作为数据 $\mathbf{x}$ 的分数函数。学习时最小化损失函数

$$L(\theta) = \sum_{t=1}^T L_t(\theta) \quad (34.49)$$

其中, $L_t(\theta)$ 是第 t 个噪声水平的损失。具体的定义是

$$L_t(\theta) = \lambda_t \mathbb{E}_{q(\mathbf{x})q_{\sigma_t}(\mathbf{x}_t|\mathbf{x})} [\|\nabla_{\mathbf{x}_t} \log q_{\sigma_t}(\mathbf{x}_t|\mathbf{x}) - \mathbf{s}_\theta(\mathbf{x}_t, \sigma_t)\|^2] \quad (34.50)$$

其中, λ_t 是系数。因为

$$\nabla_{\mathbf{x}_t} \log q_{\sigma_t}(\mathbf{x}_t|\mathbf{x}) = -\frac{\mathbf{x}_t - \mathbf{x}}{\sigma_t^2}$$

所以

$$L_t(\theta) = \lambda_t \mathbb{E}_{q(\mathbf{x})q_{\sigma_t}(\mathbf{x}_t|\mathbf{x})} \left[\left\| \mathbf{s}_\theta(\mathbf{x}_t, \sigma_t) + \frac{\mathbf{x}_t - \mathbf{x}}{\sigma_t^2} \right\|^2 \right] \quad (34.51)$$

通常选择

$$\lambda_t = \sigma_t^2$$

代入括号内就有 $\sigma_t \mathbf{s}_\theta(\mathbf{x}_t, \sigma_t)$ 和 $(\mathbf{x}_t - \mathbf{x})/\sigma_t$ 。经验上 $\mathbf{s}_\theta(\mathbf{x}_t, \sigma_t) \propto 1/\sigma_t$, 而 $(\mathbf{x}_t - \mathbf{x})/\sigma_t \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 成立, 所以, 两项属于同一数量级。

下面给出 SMLD 的学习和生成算法。

算法 34.3 (SMLD——学习算法)

输入: 训练数据集 $\mathcal{T}$ 。

输出: 神经网络 $\mathbf{s}_\theta$ 。

超参数: $\sigma_t, t = 1, 2, \dots, T$ 。

- (1) 初始化神经网络的参数 θ 。
- (2) 重复以下处理, 直到收敛:

- (2-1) 从训练数据集 $\mathcal{T}$ 中采样得到样本 $\mathbf{x}$;
- (2-2) For $(t = 1, 2, \dots, T)\{$
 根据 $q_{\sigma_t}(\mathbf{x}_t|\mathbf{x})$ 采样, 得到样本 $\mathbf{x}_t$
 $\}$
- (2-3) 计算损失函数的梯度并更新神经网络参数;

$$\nabla_{\theta} L(\theta) = \nabla_{\theta} \sum_{t=1}^T \sigma_t^2 \left(\|\mathbf{s}_{\theta}(\mathbf{x}_t, \sigma_t) + \frac{\mathbf{x}_t - \mathbf{x}}{\sigma_t^2}\|^2 \right)$$

- (3) 输出估计的神经网络模型。 ■

使用朗之万动力学, 从高噪声水平到低噪声水平进行采样, 即从第 T 个噪声水平一直到第 1 个噪声水平。在第 t 个噪声水平的采样的终值作为第 $t-1$ 个噪声水平的初值 ($t = T, T-1, \dots, 1$), 最后将第 1 个噪声水平的采样的终值作为输出。

算法 34.4 (SMLD——生成算法)

输入: 神经网络 $\mathbf{s}_{\theta}$ 。

输出: 生成的样本 $\mathbf{x}$ 。

超参数: $\sigma_t (t = T, T-1, \dots, 1), \delta, L$ 。

- (1) 随机采样得到初始样本 $\mathbf{x}^{(0)}$ 。

- (2) For $(t = T, T-1, \dots, 1)\{$

$$\delta_t = \delta \cdot \sigma_t^2 / \sigma_T^2$$

For $(l = 1, 2, \dots, L)\{$

 随机采样 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

 更新样本 $\mathbf{x}^{(l)}$

$$\mathbf{x}^{(l)} \leftarrow \mathbf{x}^{(l-1)} + \delta_t \mathbf{s}_{\theta}(\mathbf{x}^{(l-1)}, \sigma_t) + \sqrt{2\delta_t} \epsilon$$

$\}$

 设 $\mathbf{x}^{(0)} = \mathbf{x}^{(L)}$

$\}$

- (3) 输出生成的样本 $\mathbf{x}^{(0)}$ 。 ■

虽然样本数据存在于高维空间, 但通常分布于低维的流形上 (见图 34.2)。事实证明, 如果只对流形上的原始数据添加微小噪声, 并不能学好数据的生成模型。然而, 在原始数据上添加不同水平的噪声, 同时学习不同噪声水平下的去噪, 就能学好数据生成模型。在流形附近进行较小的扰动, 在

原点附近进行较大的扰动。这正是 SMLD 的基本做法，与 DDPM 的前向过程的加噪作法对应。

朗之万动力学采样一般是从高斯白噪声（标准高斯分布）开始。从高噪声到低噪声的采样可以避免陷入局部最优，因为高噪声主要分布在原点附近，而低噪声主要分布在流形附近。

比较式 (34.29) 和式 (34.51)，可以看出 DDPM 和 SMLD 都是学习分数函数，有对应的学习目标。下面可以通过随机微分方程看到两者更密切的关系。

34.4 随机微分方程方法

可以将 DDPM 和 SMLD 看作求解不同的扩散过程的随机微分方程的方法。

34.4.1 随机微分方程

随机微分方程（stochastic differential equation, SDE）是刻画随机过程演化规律的方程。最典型的情况是扩散过程。

一个粒子在流体中运动，如果其所守的外力是确定性的，其位置随时间的变化可以用常微分方程（ordinary differential equation, ODE）描述：

$$\frac{d\mathbf{x}}{dt} = \mathbf{f}(\mathbf{x}, t) \quad (34.52)$$

若粒子的运动还受到随机碰撞力的影响，则需要用随机微分方程描述这个粒子的位置变化。

随机微分方程包含确定性函数和随机过程两部分

$$d\mathbf{x} = \mathbf{f}(\mathbf{x}, t)dt + \mathbf{G}(\mathbf{x}, t)d\mathbf{w} \quad (34.53)$$

其中， $\mathbf{x}$ 表示粒子在空间中的位置， t 表示时间， $\mathbf{f}(\mathbf{x}, t)$ 是漂移系数（drift coefficient）， $\mathbf{G}(\mathbf{x}, t)$ 是扩散系数（diffusion coefficient）， $d\mathbf{w} = \boldsymbol{\epsilon}\sqrt{dt}$ ， $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 是维纳过程。注意漂移系数是向量，扩散系数是矩阵。第一项表示粒子在流体中的确定性运动，第二项表示粒子在流体中的随机游走。式 (34.53) 描述随机过程的整体规律。

维纳过程或布朗运动 $\{\mathbf{w}_t : t \geq 0\}$ 是一个满足以下条件的随机过程。 $\mathbf{w}_t$ 是表示在时刻 t 粒子位置的随机变量。(1) 初始条件： $\mathbf{w}_0 = \mathbf{0}$ 。(2) 对任意时

间序列 $0 \leq t_0 < t_1 < \dots < t_n$, 增量 $\mathbf{w}_{t_1} - \mathbf{w}_{t_0}, \mathbf{w}_{t_2} - \mathbf{w}_{t_1}, \dots, \mathbf{w}_{t_n} - \mathbf{w}_{t_{n-1}}$ 是相互独立的随机向量。(3) 对任意时刻 $s \leq t$, 增量 $\mathbf{w}_t - \mathbf{w}_s$ 服从均值向量为 $\mathbf{0}$ 、协方差矩阵为 $(t-s)\mathbf{I}$ 的多元高斯分布, 即 $\mathbf{w}_t - \mathbf{w}_s \sim \mathcal{N}(\mathbf{0}, (t-s)\mathbf{I})$ 。

朗之万动力学是随机微分方程的一个具体例子。在方程 (34.47) 中, 第一项 $\delta \nabla_{\mathbf{x}} \log p(\mathbf{x}) dt$ 是确定性的漂移项, 而第二项 $\sqrt{2\delta} d\mathbf{w}$ 是随机性的扩散项。

在机器学习中, 一个数据样本通常由高维空间中的一个向量表示, 可以类比为一个粒子。样本在空间中的随时间的随机运动轨迹可以由随机微分方程描述, 该轨迹受确定性函数和随机过程的共同影响。

对于随机微分方程, 在初始条件给定且系数满足一般正则条件 (局部 Lipschitz 连续性、时间连续性和线性增长条件) 的情况下, 其解存在且唯一。

在一般情况下, 随机微分方程的解是一个连续时间马尔可夫过程。从方程 (34.53) 可以看出, 样本轨迹的随机性来自于维纳过程。由于维纳过程具有独立增量特性, 样本在任意时刻的状态仅依赖于前一时刻的状态, 而与更早的历史无关, 即满足马尔可夫性。

反之, 一般的连续时间马尔可夫过程 (特别是扩散过程) 也可以表示为随机微分方程的解。该结论的理论证明需使用伊藤积分, 对此不予展开。

随机微分方程是基于连续时间的, 如果将时间离散化, 就得到对应的数值计算迭代公式。最基本的方法有欧拉-丸山法。事实上, 朗之万动力学的抽样算法 (34.48) 等价于使用欧拉-丸山法。

34.4.2 前向和反向扩散过程

扩散过程的前向过程和反向过程都可以由随机微分方程描述。这里考虑更具体的情况, 扩散系数 $g(t)$ 只是时间的函数, 而且是标量。

定理 34.3 (Anderson) 设扩散过程的前向过程由随机微分方程

$$d\mathbf{x} = \mathbf{f}(\mathbf{x}, t)dt + g(t)d\mathbf{w} \quad (34.54)$$

给出, 并假设相关函数满足适当的正则条件。则其对应的反向时间过程满足如下逆时间随机微分方程:

$$d\mathbf{x} = [\mathbf{f}(\mathbf{x}, t) - g^2(t)\nabla_{\mathbf{x}} \log p_t(\mathbf{x})] dt + g(t) d\bar{\mathbf{w}}, \quad (34.55)$$

其中 $\nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ 为分数函数, $\bar{\mathbf{w}}$ 表示关于逆时间的标准维纳过程。




图 34.6: 随机微分方程描述扩散过程的前向过程和反向过程

DDPM 和 SMLD 分别对应不同的前向与反向随机微分方程 (SDE)。前向 SDE 确定的条件下, 反向 SDE 可由前向 SDE 唯一确定。这两种方法的前向与反向 SDE 均可通过数值方法求解。

图 34.6 显示 SDE 描述的前向和反向过程, 在前向过程中, 漂移项和扩散项事先给定; 而在反向过程中, 扩散项仍然已知, 但漂移项中包含未知的分数函数, 需要通过学习获得。因此, 分数函数是扩散模型中最为关键的要素。

34.4.3 DDPM

在近似条件下, DDPM 的前向和反向迭代公式与欧拉-丸山法有相同的形式。

DDPM 前向过程的随机微分方程 (SDE) 为

$$dx = -\frac{\beta(t)}{2}x dt + \sqrt{\beta(t)}dw \quad (34.56)$$

用欧拉-丸山法对该随机微分方程进行数值求解。设时间步长为 Δt , 在时刻 t 对 SDE 进行离散化, 有

$$x(t + \Delta t) = x(t) + \left(-\frac{\beta(t)}{2}x(t)\right) \Delta t + \sqrt{\beta(t)}(w(t + \Delta t) - w(t))$$

由于维纳过程的增量满足

$$w(t + \Delta t) - w(t) = \sqrt{\Delta t}\epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

上式可写为

$$\mathbf{x}(t + \Delta t) = \left(1 - \frac{\beta(t)}{2}\Delta t\right) \mathbf{x}(t) + \sqrt{\beta(t)\Delta t} \boldsymbol{\epsilon} \quad (34.57)$$

将连续时间的加噪速率 $\beta(t)$ 在时间区间 Δt 内积分, 记 $\beta_t = \beta(t)\Delta t$, 利用一阶近似, 忽略 $o(\beta_t^2)$ 项, 则有

$$\mathbf{x}_t \approx \sqrt{1 - \beta_t} \mathbf{x}_{t-1} + \sqrt{\beta_t} \boldsymbol{\epsilon} \quad (34.58)$$

由此, 在一阶近似意义下, DDPM 的前向过程迭代公式与欧拉-丸山法的离散形式一致。当 $\Delta t \rightarrow 0$ 时, 该离散过程收敛到对应的随机微分方程。

根据定理 34.3, DDPM 反向过程的逆时间随机微分方程为

$$d\mathbf{x} = -\beta(t) \left(\frac{\mathbf{x}}{2} + \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) \right) dt + \sqrt{\beta(t)} d\bar{\mathbf{w}} \quad (34.59)$$

其中 $\bar{\mathbf{w}}$ 表示逆时间维纳过程。

用欧拉-丸山法对该随机微分方程进行数值求解。设时间步长为 Δt , 在时刻 t 沿逆时间对 SDE 进行离散化, 有

$$\begin{aligned} \mathbf{x}(t - \Delta t) &= \mathbf{x}(t) + \beta(t) \left(\frac{\mathbf{x}(t)}{2} + \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t)) \right) \Delta t \\ &\quad + \sqrt{\beta(t)} (\bar{\mathbf{w}}(t) - \bar{\mathbf{w}}(t - \Delta t)) \end{aligned}$$

由于逆时间维纳过程的增量满足

$$\bar{\mathbf{w}}(t) - \bar{\mathbf{w}}(t - \Delta t) = \sqrt{\Delta t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

上式可写为

$$\mathbf{x}(t - \Delta t) = \mathbf{x}(t) + \beta(t) \left(\frac{\mathbf{x}(t)}{2} + \nabla_{\mathbf{x}} \log p_t(\mathbf{x}(t)) \right) \Delta t + \sqrt{\beta(t)\Delta t} \boldsymbol{\epsilon} \quad (34.60)$$

将连续时间的加噪速率 $\beta(t)$ 在时间区间 Δt 内积分, 记 $\beta_t = \beta(t)\Delta t$, 则有

$$\mathbf{x}_{t-1} = \left(1 + \frac{\beta_t}{2}\right) \mathbf{x}_t + \beta_t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) + \sqrt{\beta_t} \boldsymbol{\epsilon} \quad (34.61)$$

利用一阶近似, 忽略 $o(\beta_t^2)$ 项, 可将上式改写为

$$\mathbf{x}_{t-1} \approx \frac{1}{\sqrt{1 - \beta_t}} (\mathbf{x}_t + \beta_t \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t)) + \sqrt{\beta_t} \boldsymbol{\epsilon} \quad (34.62)$$

在此条件下, 该迭代形式与 DDPM 反向过程中基于分数函数预测的迭代公式 (34.30) 具有相同的形式。

34.4.4 SMLD

SMLD 是从分数匹配的角度推导得出的，但也可以认为是基于扩散过程的。事实上对原始数据添加不同水平的噪声对应着前向过程，噪声水平对应着扩散步骤。

假设存在一个前向过程，是马尔可夫过程，从样本 $\mathbf{x}_{t-1}$ 到样本 $\mathbf{x}_t$ 的转移概率分布是以下高斯分布。

$$q(\mathbf{x}_t|\mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \mathbf{x}_{t-1}, (\sigma_t^2 - \sigma_{t-1}^2)\mathbf{I}) \quad (34.63)$$

$$\mathbf{x}_t = \mathbf{x}_{t-1} + \sqrt{\sigma_t^2 - \sigma_{t-1}^2} \boldsymbol{\epsilon} \quad (34.64)$$

设 $\mathbf{x}_0 = \mathbf{x}$, $\sigma_0 = 0$ 。

样本 $\mathbf{x}_t$ ($t = 1, 2, \dots, T$) 的均值和方差满足

$$\mathbb{E}(\mathbf{x}_t) = \mathbb{E}(\mathbf{x}_{t-1}) = \dots = \mathbb{E}(\mathbf{x}_1) = \mathbf{x}_0$$

$$\begin{aligned} \text{Var}(\mathbf{x}_t) &= \text{Var}(\mathbf{x}_{t-1}) + (\sigma_t^2 - \sigma_{t-1}^2)\mathbf{I} \\ &= \text{Var}(\mathbf{x}_{t-2}) + (\sigma_t^2 - \sigma_{t-2}^2)\mathbf{I} \\ &= \dots \\ &= \text{Var}(\mathbf{x}_0) + \sigma_t^2\mathbf{I} \end{aligned}$$

于是得到从样本 $\mathbf{x}_0$ 到样本 $\mathbf{x}_t$ 的转移概率分布。

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \mathbf{x}_0, \sigma_t^2\mathbf{I}) \quad (34.65)$$

与 SMLD 的第 t 个噪声水平的条件高斯分布是等价的。称式 (34.64) 为 SMLD 的前向过程的迭代公式。

SMLD 前向过程对应的随机微分方程为

$$d\mathbf{x} = \sqrt{\frac{d(\sigma^2(t))}{dt}} d\mathbf{w}, \quad (34.66)$$

其中 $\sigma^2(t)$ 为随时间变化的噪声强度函数。用欧拉-丸山法对该随机微分方程进行数值求解，并做一定的近似，得到与 SMLD 前向过程形式相同的迭代公式。

$$\mathbf{x}_t = \mathbf{x}_{t-1} + \sqrt{\sigma_t^2 - \sigma_{t-1}^2} \boldsymbol{\epsilon}. \quad (34.67)$$

根据定理 34.3, SMLD 反向过程的逆时间随机微分方程为

$$d\mathbf{x} = -\frac{d(\sigma^2(t))}{dt} \nabla_{\mathbf{x}} \log p_t(\mathbf{x}) dt + \sqrt{\frac{d(\sigma^2(t))}{dt}} d\bar{\mathbf{w}}, \quad (34.68)$$

其中 $\bar{\mathbf{w}}$ 表示逆时间维纳过程。用欧拉-丸山法对该逆时间随机微分方程进行数值求解, 并做一定的近似, 得到与 SMLD 反向过程形式近乎相同的迭代公式。

$$\mathbf{x}_{t-1} = \mathbf{x}_t + (\sigma_t^2 - \sigma_{t-1}^2) \nabla_{\mathbf{x}} \log p_t(\mathbf{x}_t) + \sqrt{\sigma_t^2 - \sigma_{t-1}^2} \boldsymbol{\epsilon}, \quad (34.69)$$

也是退火朗之万动力学的迭代公式。

所以, DDPM 和 SMLD 的前向过程和反向过程的迭代公式可以看作是求解不同的随机微分方程的近似算法。

34.5 图像生成

DDPM 和 SMLD 两个模型都被应用到了图像生成等任务, 在不同的任务上各自有自己的优势。目前在图像生成中常用 DDPM。

34.5.1 扩散模型用于图像生成

图像生成是从训练数据中学习图像的概率分布模型, 从学到的模型中采样, 自动生成新的图像数据的任务。本书介绍的生成对抗网络 GAN、变分自编码器 VAE, 以及扩散模型 DM 都可以用于图像生成。目前扩散模型, 特别是 DDPM, 是图像生成的主要技术。图像生成的结果一般由清晰度、真实性、合理性、多样性等多个指标衡量。用扩散模型生成的图片已经到了与真实图片很难区分的程度。

图 34.7 比较 GAN、VAE 以及扩散模型的学习和生成的流程。扩散模型的特点是加噪与去噪, 或者编码与解码的过程, 都是通过多个步骤的随机变换实现的, 其中的去噪或解码使用神经网络完成。VAE 使用神经网络直接完成这两个过程。GAN 使用生成网络进行去噪或解码, 使用判别网络进行评估。扩散模型的学习和生成方法具有以下几个优点。样本数据的分布, 如图像数据的分布, 是复杂的, 多步的学习有利于更准确地学习样本数据的分布。

多步的学习降低了计算的复杂度, 使复杂模型的学习变得可行。数据生成的过程也更加稳定, 生成的数据的真实性和多样性也更高。




图 34.7: 概率生成模型的比较: GAN、VAE、DM

DDPM 用于图像生成，使用的神经网络一般是 UNet 或 Transformer。模型的学习一般不在原始样本空间中进行，而是在隐空间中进行。图像生成时往往基于文本或其他信息进行。下面对两种相关的技术，隐空间中和有条件的扩散模型做介绍。

34.5.2 隐空间中的生成

将扩散模型应用于图像生成，最直接的方法是在图像数据的样本空间中学习和使用扩散模型。但因为计算量比较大，影响学习的效率和生成的速度。一个常用的方法是将图像进行压缩，将其转换成隐空间的样本，在隐空间进行扩散模型的学习和使用。常用的方法有隐式扩散模型 (latent diffusion model, LDM)。

LDM 的学习分作两步。第 1 步，针对训练数据学习一个变分自编码器 VAE，得到编码器和解码器，同时将训练数据压缩到隐空间。第 2 步，在隐空间中从被压缩的图像学习 DDPM。LDM 的生成也分作两步。第 1 步，在隐空间内使用学到的 DDPM 生成一个压缩图像。第 2 步，使用解码器将生成的压缩图像转换成图像。

样本空间表示为 $\mathbf{x} \in \mathbb{R}^{H \times W \times 3}$ ，其中 H 和 W 是图像的高度和宽度，3 是通道数。隐空间表示为 $\mathbf{z} \in \mathbb{R}^{h \times w \times c}$ ，其中 h 和 w 是压缩图像的高度和宽

度, c 表示通道数。假设有关系 $H/h = W/w = 2^m$ 成立, 其中 m 是超参数。一般取 $m = 4 \sim 8$ 。由于隐空间的维数远远小于样本空间的维数, LDM 有更高的学习效率。

图像数据内一般有一定的冗余, 所以经过压缩后, 在隐空间学习扩散模型, 生成的新的图像数据仍然具有很好的真实性, 虽然在隐空间的样本的表示人已无法理解。所以, 可以认为原始的图像空间和压缩的隐空间在视觉表示方面是基本等价的。

LDM 采用 UNet 作为 DDPM 的神经网络。UNet 是一种使用跳跃连接 (skip connection) 的卷积神经网络。UNet 的信息处理, 对输入先进行下采样, 然后进行上采样。也就是说, UNet 的网络, 中间各个隐层先由宽变窄, 再由窄变宽, 而网络的输入和输出的特征维度保持不变。另外, LDM 的隐空间中样本是 2 维压缩图像。VAE 的学习不使用平方损失函数, 而是图像处理相关的损失函数; DDPM 的学习损失函数仍然是平方损失函数 (34.20)。LDM 对图像生成的效果和效率做了很好的平衡, 目前是图像生成中主要采用的方法。

34.5.3 有条件的生成

图像生成经常是在类别、内容等的描述给定条件下进行的, 要求生成的图像遵循语言指令。这也称为有条件的生成, 反之称为无条件的生成。有条件的生成代表性的方法包括分类器引导扩散和无分类器引导。

1. 分类器引导扩散

分类器引导扩散 (classifier guided diffusion) 使用训练数据 $(\mathbf{x}, y)$, 其中 $\mathbf{x}$ 表示图像, y 表示文本。假设第 t ($t = 1, 2, \dots, T$) 步的加噪数据 $\mathbf{x}_t$ 和文本 y 的联合概率分布由扩散模型和分类器决定

$$p(\mathbf{x}_t, y) = p_{\theta}(\mathbf{x}_t)p_{\phi}(y|\mathbf{x}_t) \quad (34.70)$$

其中, $p_{\theta}(\mathbf{x}_t)$ 表示扩散模型 (DDPM), $p_{\phi}(y|\mathbf{x}_t)$ 表示分类器, θ 和 ϕ 分别是参数。

求联合概率分布的分数函数得到：

$$\begin{aligned}
 \nabla_{\mathbf{x}_t} \log p(\mathbf{x}_t, y) &= \nabla_{\mathbf{x}_t} \log p_{\theta}(\mathbf{x}_t) + \nabla_{\mathbf{x}_t} \log p_{\phi}(y|\mathbf{x}_t) \\
 &= -\frac{1}{\sqrt{1-\bar{\alpha}_t}} \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) + \nabla_{\mathbf{x}_t} \log p_{\phi}(y|\mathbf{x}_t) \\
 &= -\frac{1}{\sqrt{1-\bar{\alpha}_t}} (\boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) - \sqrt{1-\bar{\alpha}_t} \nabla_{\mathbf{x}_t} \log p_{\phi}(y|\mathbf{x}_t))
 \end{aligned} \tag{34.71}$$

这里用到分数函数和高斯噪声的关系 (34.26)。

学习过程中使用联合概率分布的分数函数。每一步用分类器的分数函数 $\nabla_{\mathbf{x}_t} \log p_{\phi}(y|\mathbf{x}_t)$ 对噪声预测 $\boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t)$ 进行调整，得到新的噪声预测

$$\bar{\boldsymbol{\epsilon}}_{\theta}(\mathbf{x}_t, t) = \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) - \lambda \sqrt{1-\bar{\alpha}_t} \nabla_{\mathbf{x}_t} \log p_{\phi}(y|\mathbf{x}_t) \tag{34.72}$$

其中，系数 λ 是超参数，控制分类器对噪声预测的影响程度。当 $\lambda = 0$ 时，方法变成 DDPM；当 $\lambda \neq 0$ 时，DDPM 中的去噪预测根据分类器的分数函数进行调整。

有分类器引导扩散的缺点是需要训练扩散模型和分类器两个神经网络。无分类器引导只用一个神经网络，就能完成有条件生成的任务。

2. 无分类器引导

无分类器引导 (classifier free guidance) 也使用训练数据 $(\mathbf{x}, y)$ 。用一个统一的神经网络既学习有条件的扩散模型 $p_{\theta}(\mathbf{x}|y)$ 又学习无条件的扩散模型 $p_{\theta}(\mathbf{x})$ 。因为有条件模型的网络是

$$\boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t, y)$$

无条件模型的网络是有条件模型的网络的特殊情况。

$$\boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t) = \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t, \phi)$$

其中， ϕ 表示一个常量，如 0 向量。

基于与有分类器引导同样的推导，得出 DDPM 学习过程中用统一网络进行噪声预测的方法：

$$\bar{\boldsymbol{\epsilon}}_{\theta}(\mathbf{x}_t, t, y) = \boldsymbol{\epsilon}_{\theta}(\mathbf{x}_t, t, y) - \lambda \sqrt{1-\bar{\alpha}_t} \nabla_{\mathbf{x}_t} \log p_{\theta}(y|\mathbf{x}_t) \tag{34.73}$$

其中， $\nabla_{\mathbf{x}_t} \log p_{\theta}(y|\mathbf{x}_t)$ 是隐式的分类器的分数函数。

根据贝叶斯定理，有

$$\begin{aligned}\nabla_{\mathbf{x}_t} \log p_{\theta}(y|\mathbf{x}_t) &= \nabla_{\mathbf{x}_t} \log p_{\theta}(\mathbf{x}_t|y) - \nabla_{\mathbf{x}_t} \log p_{\theta}(\mathbf{x}_t) \\ &= -\frac{1}{\sqrt{1-\bar{\alpha}_t}} (\epsilon_{\theta}(\mathbf{x}_t, t, y) - \epsilon_{\theta}(\mathbf{x}_t, t))\end{aligned}\quad (34.74)$$

代入式 (34.74) 得到：

$$\begin{aligned}\bar{\epsilon}_{\theta}(\mathbf{x}_t, t, y) &= \epsilon_{\theta}(\mathbf{x}_t, t, y) - \lambda \sqrt{1-\bar{\alpha}_t} \nabla_{\mathbf{x}_t} \log p_{\theta}(y|\mathbf{x}_t) \\ &= \epsilon_{\theta}(\mathbf{x}_t, t, y) + \lambda (\epsilon_{\theta}(\mathbf{x}_t, t, y) - \epsilon_{\theta}(\mathbf{x}_t, t)) \\ &= (1 + \lambda) \epsilon_{\theta}(\mathbf{x}_t, t, y) - \lambda \epsilon_{\theta}(\mathbf{x}_t, t)\end{aligned}\quad (34.75)$$

这样学习过程中使用统一网络 $\bar{\epsilon}_{\theta}(\mathbf{x}_t, t, y)$ 即可。

当 $\lambda = -1$ 时变成无条件模型的网络，当 $\lambda = 0$ 时变成有条件模型的网络。当 $\lambda > 0$ 时，会增强有条件模型的噪声预测，同时抑制无条件模型的噪声预测，使得生成的样本与给定的条件具有更强的相关性。这便是条件生成中使用无分类器引导的主要目的，即调整条件的强度。

神经网络的训练可以结合有条件模型和无条件模型统一进行。例如对训练数据按照一定的比例将 y 设置为 ϕ ，而这个比例是超参数。

本章概要

1. 扩散模型的基本思想 扩散模型是基于扩散过程定义的概率生成模型。扩散过程由前向过程和反向过程组成。前向过程将数据逐步转换为高斯白噪声；反向过程将高斯白噪声逐步转换为数据。前向过程和反向过程均为马尔可夫过程。前向过程事先定义，模型的学习在反向过程中展开。

代表性方法包括去噪扩散概率模型 (DDPM) 和基于分数匹配与朗之万动力学的模型 (SMLD)。

2. DDPM 的基本思想 DDPM 的前向过程从原始数据 $\mathbf{x}_0$ 开始，通过 $t = 1, 2, \dots, T$ 个步骤逐渐向数据中添加噪声，直到得到近似高斯白噪声 $\mathbf{x}_T$ 。反向过程从 $\mathbf{x}_T$ 开始，通过 $T-1, \dots, 1, 0$ 个步骤逐渐去除噪声，以还原原始数据 $\mathbf{x}_0$ 。

学习的目标是针对反向过程，训练一个神经网络来预测前向过程中每一步所添加的噪声。

3. DDPM 的前向与反向过程 DDPM 的前向过程是马尔可夫过程，其转移概率为

$$q(\mathbf{x}_t | \mathbf{x}_{t-1}) = \mathcal{N}(\mathbf{x}_t; \sqrt{\alpha_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}), \quad \alpha_t = 1 - \beta_t.$$

反向过程同样是马尔可夫过程。由前向过程可以计算条件分布

$$q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) = \mathcal{N}(\mathbf{x}_{t-1}; \tilde{\boldsymbol{\mu}}_t(\mathbf{x}_t, \mathbf{x}_0), \tilde{\boldsymbol{\beta}}_t \mathbf{I}).$$

DDPM 基于变分原理进行学习，通过最大化对数证据 $\log p(\mathbf{x}_0)$ 的下界。

假设反向过程的转移概率分布为高斯分布，并用神经网络参数化：

$$p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1} | \mathbf{x}_t) = \mathcal{N}(\mathbf{x}_{t-1}; \boldsymbol{\mu}_{\boldsymbol{\theta}}(\mathbf{x}_t, t), \boldsymbol{\Sigma}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)).$$

4. DDPM 的变分目标 期望证据下界 (ELBO) 满足

$$\mathbb{E}_{q(\mathbf{x}_0)} \log p_{\boldsymbol{\theta}}(\mathbf{x}_0) \geq \mathbb{E}_{q(\mathbf{x}_{0:T})} \left[\log \frac{p_{\boldsymbol{\theta}}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T} | \mathbf{x}_0)} \right].$$

其主要损失项为

$$L_{t-1}(\boldsymbol{\theta}) = \mathbb{E} [\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) \parallel p_{\boldsymbol{\theta}}(\mathbf{x}_{t-1} | \mathbf{x}_t))], \quad t = 2, \dots, T.$$

在固定协方差的条件下，该损失可简化为噪声预测误差：

$$L'_{t-1}(\boldsymbol{\theta}) = \mathbb{E} [\|\boldsymbol{\epsilon} - \boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{x}_t, t)\|^2].$$

前向过程可写为

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}),$$

其中 $\bar{\alpha}_t = \prod_{s=1}^t \alpha_s$ 。

反向采样过程为

$$\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}_{\boldsymbol{\theta}}(\mathbf{x}_t, t) \right) + \sqrt{\beta_t} \boldsymbol{\epsilon}.$$

分数函数与噪声的关系为

$$\nabla_{\mathbf{x}_t} \log q(\mathbf{x}_t) = -\frac{1}{\sqrt{1 - \bar{\alpha}_t}} \boldsymbol{\epsilon}.$$

5. SMLD 的基本思想 SMLD 直接学习并使用分数函数。学习阶段，在原始数据 $\mathbf{x}$ 上添加不同程度的高斯噪声 $q_{\sigma_t}(\mathbf{x}_t | \mathbf{x})$ ，并训练神经网络拟合不同噪声水平 σ_t 下数据分布的分数函数 $\nabla_{\mathbf{x}_t} \log q_{\sigma_t}(\mathbf{x}_t | \mathbf{x})$ 。

生成阶段，使用朗之万动力学进行采样，逐步降低噪声水平，最终生成接近原始数据分布的样本。

6. SMLD 的分数匹配 分数函数定义为

$$\nabla_{\mathbf{x}} \log p(\mathbf{x}).$$

分数匹配使用神经网络 $\mathbf{s}_{\theta}(\mathbf{x})$ 表示分数函数，并最小化

$$L(\theta) = \mathbb{E}_{q(\mathbf{x})} \left[\frac{1}{2} \|\nabla_{\mathbf{x}} \log q(\mathbf{x}) - \mathbf{s}_{\theta}(\mathbf{x})\|^2 \right].$$

去噪分数匹配使用加噪分布

$$q_{\sigma}(\tilde{\mathbf{x}} | \mathbf{x}) = \mathcal{N}(\tilde{\mathbf{x}}; \mathbf{x}, \sigma^2 \mathbf{I}),$$

其损失函数为

$$L(\theta) = \mathbb{E} \left[\frac{1}{2} \|\mathbf{s}_{\theta}(\tilde{\mathbf{x}}) - \nabla_{\tilde{\mathbf{x}}} \log q_{\sigma}(\tilde{\mathbf{x}} | \mathbf{x})\|^2 \right].$$

7. 朗之万动力学 朗之万动力学用于从目标分布中采样：

$$\mathbf{x}^{(l)} = \mathbf{x}^{(l-1)} + \delta \nabla_{\mathbf{x}} \log p(\mathbf{x}^{(l-1)}) + \sqrt{2\delta} \epsilon,$$

当 $\delta \rightarrow 0$ 且 $L \rightarrow \infty$ 时，样本分布收敛于 $p(\mathbf{x})$ 。

8. SMLD 的学习与采样 SMLD 使用不同噪声水平的条件分布

$$q_{\sigma_t}(\mathbf{x}_t | \mathbf{x}) = \mathcal{N}(\mathbf{x}_t; \mathbf{x}, \sigma_t^2 \mathbf{I}),$$

并学习条件分数模型 $\mathbf{s}_{\theta}(\mathbf{x}_t, \sigma_t)$ ，其损失为

$$L_t(\theta) = \lambda_t \mathbb{E} \left[\left\| \mathbf{s}_{\theta}(\mathbf{x}_t, \sigma_t) + \frac{\mathbf{x}_t - \mathbf{x}}{\sigma_t^2} \right\|^2 \right].$$

生成时，从高噪声到低噪声水平依次使用朗之万动力学采样。

9. 随机微分方程 (SDE) 视角 DDPM 和 SMLD 均可视为连续时间随机微分方程 (SDE) 的离散化形式。其前向和反向更新公式对应于 SDE 的数值求解。

10. 隐式扩散模型 隐式扩散模型首先训练变分自编码器 (VAE) 将数据映射至隐空间, 随后在隐空间中训练 DDPM。生成时先在隐空间生成样本, 再通过解码器还原至数据空间。

11. 条件生成与引导 分类器引导扩散通过分类器分数函数调整噪声预测:

$$\bar{\epsilon}_{\theta} = \epsilon_{\theta} - \lambda \sqrt{1 - \bar{\alpha}_t} \nabla_{\mathbf{x}_t} \log p_{\phi}(y | \mathbf{x}_t).$$

无分类器引导使用统一模型:

$$\bar{\epsilon}_{\theta} = (1 + \lambda) \epsilon_{\theta}(\mathbf{x}_t, t, y) - \lambda \epsilon_{\theta}(\mathbf{x}_t, t).$$

继续阅读

扩散模型的主要论文包括介绍 DDPM 和 SMLD 的文献 [1]–[3]。与 SMLD 相关的论文还有文献 [4] 和文献 [5]。文献 [6] 探讨了随机微分方程与扩散模型之间的关系。DDIM (Denoising Diffusion Implicit Model) [7] 能够进一步提高 DDPM 的生成效率。在图像生成领域被广泛使用的隐式扩散模型 (Latent Diffusion Model) 和 UNet 分别在文献 [8] 和文献 [9] 中被提出。分类器引导扩散和无分类器引导的思想可参见文献 [10] 和文献 [11]。若需更全面地了解扩散模型, 可参考综述和介绍性文章 [12–15]。

习 题

34.1 DDPM 的前向过程中, 当 t 趋于无穷时, 转移概率分布 $q(\mathbf{x}_t | \mathbf{x}_{t-1})$ 趋于标准高斯分布。说明原因。

34.2 证明 DDPM 中以下关系成立

$$\mathbb{E}_{q(\mathbf{x}_t)} [\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t) || p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t))] = \mathbb{E}_{q(\mathbf{x}_0, \mathbf{x}_t)} [\text{KL}(q(\mathbf{x}_{t-1} | \mathbf{x}_t, \mathbf{x}_0) || p_{\theta}(\mathbf{x}_{t-1} | \mathbf{x}_t))] + C$$

其中 C 是不依赖于 θ 的常数。提示: 利用 DDPM 变分推理推导中使用的技巧。

34.3 DDPM 的神经网络也可以是预测原始数据 $\mathbf{x}_0$ ，这与预测高斯噪声 ϵ 是等价的。请给出此时的反向过程与前向过程的迭代公式，并解释两者的等价性。

34.4 整理 DDPM 的分数函数形式的学习算法和生成算法，列出与 SMLD 的不同点。

34.5 证明一元高斯分布 $x \sim p(x) = \mathcal{N}(x; \mu, \sigma^2)$ 的 Tweedie 公式，其中数据 x 是随机变量，均值 μ 是随机变量，方差 σ^2 是定量。

$$\mathbb{E}[\mu|x] = x + \sigma^2 \frac{d}{dx} \log p(x)$$

34.6 实现朗之万动力学的采样算法，并应用于以下高斯混合模型的采样。

$$p(x) = \pi_1 \mathcal{N}(x; \mu_1, \sigma_1^2) + \pi_2 \mathcal{N}(x; \mu_2, \sigma_2^2)$$

其中， $\pi_1 = 0.6$ ， $\pi_2 = 0.4$ ， $\mu_1 = 5$ ， $\mu_2 = -4$ ， $\sigma_1 = 0.5$ ， $\sigma_2 = 0.4$ 。

34.7 针对习题 34.6 中的高斯混合模型，使用 DDPM 的公式 (34.4) 和 (34.21) 进行前向过程和反向过程的迭代，并画出 100 个样本随时间随机演化的路径图。

34.8 验证 SMLD 的前向与反向迭代公式，在连续时间极限下，与其对应随机微分方程的欧拉-丸山数值解一致。

34.9 推导无分类器引导的分数函数形式

$$\nabla_{\mathbf{x}_t} \log p_{\theta}(\mathbf{x}_t|y) = \gamma \mathbf{s}_{\theta}(\mathbf{x}_t, t, y) + (1 - \gamma) \mathbf{s}_{\theta}(\mathbf{x}_t, t)$$

其中， γ 是系数。

参考文献

- [1] SOHL-DICKSTEIN J, WEISS E, MAHESWARANATHAN N, et al. Deep unsupervised learning using nonequilibrium thermodynamics[C]//Proceedings of the 32nd International Conference on Machine Learning. PMLR, 2015: 2256–2265.
- [2] SONG Y, ERMON S. Generative modeling by estimating gradients of the data distribution[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [3] HO J, JAIN A, ABBEEL P. Denoising diffusion probabilistic models[J]. Advances in Neural Information Processing Systems, 2020, 33: 6840–6851.

- [4] HYVÄRINEN A. Estimation of non-normalized statistical models by score matching[J]. *Journal of Machine Learning Research*, 2005, 6(4): 695–709.
- [5] VINCENT P. A connection between score matching and denoising autoencoders[J]. *Neural Computation*, 2011, 23(7): 1661–1674.
- [6] SONG Y, SOHL-DICKSTEIN J, KINGMA D P, et al. Score-based generative modeling through stochastic differential equations[C]//*International Conference on Learning Representations*, 2021.
- [7] SONG J, MENG C, ERMON S. Denoising diffusion implicit models[C]//*International Conference on Learning Representations*, 2021.
- [8] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022: 10684–10695.
- [9] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional networks for biomedical image segmentation[C]//*Medical Image Computing and Computer-Assisted Intervention*. Springer, 2015: 234–241.
- [10] NICHOL A Q, DHARIWAL P. Improved denoising diffusion probabilistic models. *International Conference on Machine Learning*. PMLR, 2021: 8162–8171.
- [11] HO J, SALIMANS T. Classifier-free diffusion guidance. *NeurIPS 2021 Workshop on Deep Generative Models and Downstream Applications*, 2021.
- [12] WENG L. What are diffusion models? Lil’Log, <https://lilianweng.github.io/posts/2021-07-11-diffusion-models/>, 2021.
- [13] LUO C. Understanding diffusion models: A unified perspective. *arXiv preprint*, arXiv:2208.11970, 2022.
- [14] CHAN S H. Tutorial on diffusion models for imaging and vision. *arXiv preprint*, arXiv:2403.18103, 2024.
- [15] LAI CH, SONG Y, KIM D, MITSUFUJI Y, ERMON S. The principles of diffusion models. *arXiv preprint arXiv:2510.21890*, 2025.